



دانشگاه صنعتی امیرکبیر

(پلی تکنیک تهران)

دانشکده مهندسی کامپیوتر و فناوری اطلاعات

پروژه کارشناسی

تشخیص فعالیت‌های انسانی مبتنی بر گوشی‌های
هوشمند با استفاده از روشهای یادگیری عمیق

نگارش

طهورا مجلسی

استاد راهنما

دکتر ناظر فرد

شهریور ۱۴۰۲

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

تقدیم به پدر و مادر عزیز و مهربانم که در سختی ها و دشواری های زندگی همواره یاری دلسوز و فداکار و پشتیبانی محکم و مطمئن برایم
بوده اند.

سپاس‌گزاری

سپاس پروردگار یکتا را که هستیمان بخشید و به طریق علم و دانش رهنمودمان شد و به همنشینی رهروان علم و دانش مفتخرمان نمود. از خانواده مهربانم که همواره در طول زندگی برای شادکامی من حمایتی به جان خریدند تشکر می‌کنم، .

بی تردید تهیه‌ی این گزارش بدون راهنمایی‌های ارزشمند استاد بزرگوار جناب آقای دکتر ناظر فرد میسر نمی‌شد. پس بر خود واجب می‌دانم از راهنمایی‌های ایشان صمیمانه سپاس‌گزاری کنم .

از استاد گرانقدر ، جناب آقای دکتر رحمتی که زحمت دآوری این پایان نامه را به عهده داشتند و به مطالعه‌ی آن پرداختند، سپاس‌گزاری می‌کنم.

طورا مجلسی

شهریور ۱۴۰۲

چکیده

در حال حاضر گوشی‌های هوشمند به طور پراکنده در تمام جوامع وجود دارند. گوشی‌های هوشمند سنسورهای متعدد داخلی زیادی دارند که اندازه‌گیری مداوم فعالیت‌های روزمره انسان‌ها را امکان‌پذیر می‌کنند. این ویژگی‌ها باعث می‌شوند که گوشی‌های هوشمند به ویژه برای تحقیقات در زمینه سلامت مناسب باشند.

تشخیص فعالیت‌های انسانی یکی از مهم‌ترین مسائل تقسیم بندی داده‌های سری زمانی است. در واقع هدف این پژوهش شناسایی رفتار افراد بر اساس داده‌ی سنسورهای گوشی‌های همراه، تبلت‌ها و ساعت‌های هوشمند است. با جمع‌آوری این داده‌ها از تعداد زیادی کاربر می‌توانیم با استفاده از روش‌های یادگیری عمیق رفتار افراد را شناسایی کنیم. هدف از یک سیستم تشخیص فعالیت، شناسایی فعالیت‌های انجام شده توسط انسان بر اساس مجموعه‌ای از مشاهدات وی و محیط اطرافش است. این فرآیند بر اساس داده‌های ژيروسکوپ و شتاب‌سنج گوشی‌های هوشمند و پوشیدنی‌های هوشمند است.

تشخیص فعالیت انسانی یک حوزه است که از سیگنال‌های سری زمانی خامی که از طریق حسگرهای تعبیه شده در گوشی‌های هوشمند و دستگاه‌های قابل پوشیدن جمع‌آوری می‌شوند، فعالیت‌های انسانی را استنباط می‌کند. این حوزه در محیط‌های مختلف خانه‌های هوشمند توجه زیادی کسب کرده است، به ویژه برای نظارت مداوم بر رفتارهای انسانی در محیط‌های زندگی هوش مصنوعی به منظور ارائه مراقبت از سالمندان و بازسازی. این سیستم از مازول‌های عملیاتی مختلفی مانند جمع‌آوری داده، پیش‌پردازش برای حذف نویز و اشکال، استخراج ویژگی، انتخاب ویژگی و دسته‌بندی پیروی می‌کند. به تازگی، انواعی از تکنیک‌های برتر فرآیند استخراج و انتخاب ویژگی را ارائه داده‌اند که با استفاده از دسته‌بندی‌های یادگیری ماشین سنتی دسته‌بندی می‌شوند. با این حال، بیشتر تکنیک‌ها از فرآیندهای ساده استخراج ویژگی استفاده می‌کنند که قادر به تشخیص فعالیت‌های پیچیده نیستند. با ظهور و پیشرفت منابع محاسباتی بالا، تکنیک‌های یادگیری عمیق به طور گسترده در انواع سیستم‌های تشخیص فعالیت انسانی برای بازیابی ویژگی‌ها و دسته‌بندی به طور کارآمد استفاده می‌شوند.

در این پژوهش به تشخیص فعالیت انسان با استفاده از مدل‌های یادگیری ماشین و یادگیری عمیق به تشخیص شش نوع فعالیت می‌پردازد. در این پروژه با استفاده از مجموعه داده‌های UCI به تشخیص و طبقه‌بندی کردن فعالیت‌های افراد براساس داده‌های ژيروسکوپ و شتاب‌سنج تلفن‌های همراه آنها می‌پردازیم و با استفاده از مدل‌های یادگیری عمیق فعالیت‌های زیر را تشخیص می‌دهیم: نشستن، ایستادن، راه‌رفتن، دراز کشیدن، از پله بالا رفتن و از پله پایین آمدن. ابتدا روی داده‌ها یک سری پیش‌پردازش انجام می‌دهیم و سپس از شبکه‌های حافظه طولانی کوتاه مدت، شبکه کانولوشنی، شبکه حافظه طولانی کوتاه مدت دو طرفه و شبکه عمیق کانولوشنی حافظه طولانی

کوتاه مدت برای تشخیص فعالیت‌های انسانی استفاده می‌کنیم. پس از آموزش مدل‌های یادگیری عمیق و انتخاب بهترین آنها از نظر عملکرد آنها را ذخیره می‌کنیم. گوشی‌های هوشمند برای تحقیقات در زمینه تشخیص فعالیت انسانی در علوم سلامت مناسب هستند. برای تأثیر گذاری در سطح گسترده، تحقیقات آینده باید بر تقویت کیفیت داده‌های جمع‌آوری شده، حل مشکل داده‌های گم‌شده، جلب شرکت‌کنندگان و فعالیت‌های متنوع‌تر، کاهش الزامات مربوط به قرارگیری گوشی، ارائه اطلاعات جامع‌تر در مورد شرکت‌کنندگان تحقیق، و اشتراک کد منبع روش‌ها و الگوریتم‌های پیاده‌سازی شده تمرکز کنند.

واژه‌های کلیدی:

تشخیص فعالیت انسانی، شبکه حافظه طولانی کوتاه مدت، شبکه کانولوشنی، شبکه عمیق کانولوشنی حافظه کوتاه مدت ماندگار

فهرست مطالب

صفحه

عنوان

۱	مقدمه و طرح مسئله
۲	۱-۱ مقدمه
۳	۲-۱ طرح مسئله
۵	۲ مفاهیم پایه
۶	۱-۲ معرفی روش‌های تشخیص فعالیت انسانی
۶	۱-۱-۲ رویکرد یادگیری ماشینی
۶	۲-۱-۲ رویکرد یادگیری عمیق
۶	۲-۲ معرفی شبکه عصبی و اجزای آن ^۱
۶	۱-۲-۲ توضیح شبکه عصبی
۷	۲-۲-۲ معرفی اجزای شبکه عصبی مصنوعی
۸	۳-۲-۲ تابع فعال‌سازی ^۲
۱۲	۴-۲-۲ تابع بهینه‌سازی
۱۳	۵-۲-۲ تنظیم‌کننده ^۳
۱۴	۶-۲-۲ توضیح یادگیری در شبکه‌های عصبی
۱۴	۷-۲-۲ توضیح گرادیان کاهشی ^۴
۱۶	۸-۲-۲ توضیح انتشار رو به عقب ^۵
۱۷	۹-۲-۲ تعریف تابع هزینه ^۶
۲۱	۳-۲ معرفی کلی شبکه‌های عصبی عمیق
۲۱	۱-۳-۲ شبکه عصبی کانولوشنی ^۷
۲۳	۲-۳-۲ شبکه عصبی بازگشتی ^۸
۲۴	۳-۳-۲ شبکه عصبی حافظه کوتاه مدت ماندگار ^۹
۲۸	۴-۳-۲ شبکه عصبی حافظه کوتاه مدت ماندگار دو طرفه ^{۱۰}

Artificial Neural network^۱

Activation function^۲

Regularization^۳

Gradient Descent^۴

Back Propagation^۵

Cost function^۶

CNN^۷

RNN^۸

LSTM^۹

bi-LSTM^{۱۰}

۲۹	۵-۳-۲ شبکه عصبی کانولوشنی حافظه کوتاه مدت ماندگار ^{۱۱}
۳۱	۳ پیشینه موضوع
۳۲	۱-۳ ماشین بردار پشتیبان ^{۱۲}
۳۳	۲-۳ درخت تصمیم‌گیری ^{۱۳}
۳۳	۳-۳ یادگیری انتقالی ^{۱۴}
۳۴	۴-۳ H-SVM
۳۷	۵-۳ جنگل تصادفی ^{۱۵}
۳۸	۴ ابزارهای پیاده‌سازی
۳۹	۱-۴ ابزارها و کتابخانه‌های مورد استفاده
۳۹	۱-۱-۴ تنسورفلو ^{۱۶}
۳۹	۲-۱-۴ نامپای ^{۱۷}
۳۹	۳-۱-۴ کراس ^{۱۸}
۴۰	۴-۱-۴ پانداس ^{۱۹}
۴۰	۵-۱-۴ متپلات لیب ^{۲۰}
۴۰	۶-۱-۴ سایکیت‌لرن ^{۲۱}
۴۱	۵ پیاده‌سازی مدل‌ها و پیش‌پردازش داده‌ها
۴۲	۱-۵ معرفی مجموعه داده‌ها و پیش‌پردازش آن
۴۲	۱-۱-۵ معرفی مجموعه داده‌ها
۴۷	۲-۱-۵ تحلیل مجموعه داده‌ها
۴۷	۳-۱-۵ پیش‌پردازش داده‌ها
۵۱	۲-۵ ارزیابی مدل‌های شبکه عصبی مصنوعی
۵۱	۱-۲-۵ شبکه عصبی کانولوشنی

^{۱۱} CNN-LSTM

^{۱۲} Support Vector Machine

^{۱۳} Decision Tree

^{۱۴} Transfer learning

^{۱۵} Random Forest

^{۱۶} Tensorflow

^{۱۷} numpy

^{۱۸} Keras

^{۱۹} pandas

^{۲۰} matplotlib

^{۲۱} Scikit-learn

۵۵	۲-۲-۵ شبکه عصبی عمیق کانولوشنی حافظه کوتاه مدت ماندگار ^{۲۲}
۵۹	۳-۲-۵ شبکه عصبی حافظه طولانی کوتاه مدت
۵۹	۴-۲-۵ شبکه عصبی حافظه طولانی کوتاه مدت نوع اول
۶۲	۵-۲-۵ شبکه عصبی حافظه طولانی کوتاه مدت دوطرفه ^{۲۳} در معماری نوع اول
۶۴	۶-۲-۵ شبکه عصبی حافظه کوتاه مدت ماندگار پشته‌ای
۶۷	۷-۲-۵ شبکه عصبی حافظه طولانی کوتاه مدت دوطرفه در معماری نوع دوم
۶۹	۸-۲-۵ شبکه منتخب
۷۱	۶ نتیجه‌گیری و پیشنهادات
۷۲	۱-۶ جمع‌بندی و نتیجه‌گیری
۷۳	۲-۶ پیشنهادات
۷۴	کتاب‌نامه

^{۲۲} Deep CNN-LSTM

^{۲۳} Bidirectional LSTM

فهرست تصاویر

شکل

صفحه

۱-۲	ساختر یک شبکه عصبی [۱]	۸
۲-۲	تابع فعال سازی سیگموئید [۲]	۹
۳-۲	تابع فعال سازی تانژانت هذلولوی [۲]	۱۰
۴-۲	تابع فعال ساز یکسوساز [۲]	۱۲
۵-۲	تفاوت نرخ یادگیری کوچک و بزرگ [۳]	۱۵
۶-۲	ساختر شبکه عصبی حافظه کوتاه مدت ماندگار [۴]	۲۴
۷-۲	گیت فراموشی	۲۶
۸-۲	گیت ورودی [۵]	۲۷
۹-۲	گیت خروجی [۵]	۲۸
۱۰-۲	شکل مدل حافظه کوتاه مدت ماندگار دوطرفه [۶]	۲۸
۱-۳	مدل svm [۶]	۳۵
۲-۳	دقت مدل H-SVM [۶]	۳۶
۱-۵	سیگنال خام شتاب سنج	۴۲
۲-۵	سیگنال خام ژيروسکوپ	۴۳
۳-۵	سیگنال مربوط به راه رفتن	۴۳
۴-۵	سیگنال مربوط به از پله بالا رفتن	۴۴
۵-۵	سیگنال مربوط به از پله پایین آمدن	۴۴
۶-۵	سیگنال مربوط به نشستن	۴۵
۷-۵	سیگنال مربوط به ایستادن	۴۵
۸-۵	سیگنال مربوط به دراز کشیدن	۴۶
۹-۵	سیگنال شتاب بعد از فیلتر میانه	۴۸
۱۰-۵	سیگنال ژيروسکوپ بعد از فیلتر میانه	۴۹
۱۱-۵	سیگنال شتاب بعد از فیلتر میانه و باترورث	۵۰
۱۲-۵	سیگنال ژيروسکوپ بعد از فیلتر میانه و باترورث	۵۰
۱۳-۵	معماری شبکه عصبی کانولوشنی به شکل کلی	۵۲
۱۴-۵	معماری شبکه عصبی کانولوشنی	۵۳
۱۵-۵	نمودار خطا و صحت برای شبکه عصبی کانولوشنی	۵۴
۱۶-۵	نتایج آزمایش داده های تست بر روی شبکه عصبی کانولوشن	۵۴
۱۷-۵	ماتریس درهم ریختگی برای شبکه عصبی کانولوشنی	۵۵
۱۸-۵	نمودار کلی شبکه کانولوشنی حافظه کوتاه مدت ماندگار	۵۶
۱۹-۵	نمودار شبکه کانولوشنی حافظه کوتاه مدت ماندگار	۵۷

- ۵-۲۰ نمودار خطا و صحت برای شبکه عصبی کانولوشنی حافظه طولانی کوتاه مدت ۵۸
- ۵-۲۱ نتایج آزمایش داده‌های تست بر روی شبکه عصبی کانولوشنی حافظه کوتاه مدت ماندگار ۵۸
- ۵-۲۲ ماتریس درهم ریختگی شبکه عصبی کانولوشنی حافظه کوتاه مدت ماندگار ۵۹
- ۵-۲۳ معماری کلی شبکه حافظه کوتاه مدت طولانی ۶۰
- ۵-۲۴ معماری شبکه حافظه کوتاه مدت طولانی ۶۰
- ۵-۲۵ نمودار خطا و صحت برای شبکه حافظه طولانی کوتاه مدت نوع اول ۶۱
- ۵-۲۶ نتایج آزمایش داده‌های تست بر روی شبکه حافظه طولانی کوتاه مدت نوع اول ۶۱
- ۵-۲۷ ماتریس درهم ریختگی برای شبکه عصبی حافظه طولانی کوتاه مدت نوع اول ۶۲
- ۵-۲۸ نمودار خطا و صحت برای شبکه حافظه طولانی کوتاه مدت دو طرفه نوع اول ۶۳
- ۵-۲۹ نتایج آزمایش داده‌های تست بر روی شبکه حافظه طولانی کوتاه مدت دوطرفه نوع اول ۶۳
- ۵-۳۰ ماتریس درهم‌ریختگی شبکه حافظه طولانی کوتاه مدت دوطرفه نوع اول ۶۴
- ۵-۳۱ معماری کلی شبکه حافظه کوتاه مدت ماندگار پشته‌ای ۶۵
- ۵-۳۲ معماری شبکه حافظه کوتاه مدت ماندگار پشته‌ای ۶۵
- ۵-۳۳ نمودار خطا و صحت برای شبکه حافظه کوتاه مدت ماندگار پیچشی ۶۶
- ۵-۳۴ نتایج آزمایش داده‌های تست بر روی شبکه عصبی حافظه کوتاه مدت ماندگار پشته‌ای ۶۷
- ۵-۳۵ ماتریس درهم‌ریختگی شبکه حافظه کوتاه مدت ماندگار پشته‌ای ۶۷
- ۵-۳۶ معماری کلی شبکه حافظه کوتاه مدت دو طرفه ماندگار پشته‌ای ۶۸
- ۵-۳۷ نمودار خطا و صحت برای شبکه حافظه کوتاه مدت ماندگار دوطرفه نوع دوم ۶۸
- ۵-۳۸ نتایج آزمایش داده‌های تست بر روی شبکه حافظه کوتاه مدت ماندگار دوطرفه نوع دوم ۶۹
- ۵-۳۹ ماتریس درهم‌ریختگی شبکه حافظه طولانی کوتاه مدت دوطرفه نوع دوم ۶۹

صفحه	جدول	فهرست جداول
۷۳	۱-۶ مقایسه بهترین شبکه‌ها از هر نوع	

فهرست نمادها

نماد	مفهوم
TP	مثبت صحیح
FP	مثبت غلط
TN	منفی صحیح
FN	منفی غلط
Σ	جمع
X	ورودی شبکه
Y	خروجی شبکه
W	وزن شبکه
$\hat{y}_t$	نتیجه پیش بینی شده مدل

فصل اول

مقدمه و طرح مسئله

۱-۱ مقدمه

پیشرفت در علم همیشه بر اساس داده بوده است. با گذشت زمان و استفاده ی گسترده از تلفن های همراه که هر کدام سنسور های متعددی مثل شتاب سنج و GPS دارند می توان جنبه های مختلف زندگی را با استفاده از داده های دقیق و مستمر این سنسور ها ثبت کرد. یکی از جنبه های مهم فعالیت فیزیکی است. چنین گسترشی در پذیرش تلفن های هوشمند در سراسر جهان فرصت بی سابقه ای را برای جمع آوری داده ها برای مطالعه رفتار و سلامت انسان ایجاد کرده است. تشخیص فعالیت انسان با استفاده از حسگرهای تلفن هوشمند به عنوان یک مسئله دسته بندی سری زمانی چند متغیره محسوب می شود که از سیگنالهای حسگر یک بعدی استفاده کرده و ویژگی های ممتازی را جهت تشخیص فعالیت ها با استفاده از یک دسته بندی کننده استخراج می کند.

فعالیت های انسان در واقع به صورت داده های ساختارهای سلسله مراتبی بوده و در مورد استفاده از حسگرها برای تشخیص فعالیت انسان، به شدت در معرض تغییرات کوچک در داده های ورودی قرار دارند. در واقع شکل ها و سبک های متفاوتی برای انجام دادن یک فعالیت وجود دارد و هر فعالیت قابل تقسیم شدن به فعالیت های کوچکتر است. این ویژگی های فعالیت ها و سیگنال های سری زمانی به عنوان اطلاعاتی بسیار مفید در صورتیکه به صورت مناسب مورد استفاده قرار گیرند، شناخته می شوند.

گوشی های هوشمند ابزارهای جمع آوری خوبی برای اندازه گیری هدفمند و قابل تکرار عوامل خطر سنتی و نوظهور برای جمعیت انسانی هستند. اهمیت این موضوع این است که برخلاف برخی از ردیاب های قابل پوشیدن، گوشی های هوشمند به طور گسترده در دسترس برای کاربران تمام سنین در اقتصادهای پیشرفته و نوظهور شده اند. از پشتیبانی بیشتری که تحقیقات سلامت با استفاده از دستگاه های قابل حمل دیگر، به ویژه شتاب سنج های قابل پوشیدن، انجام شده است برای انتقال این گوشی ها به تحقیقات در حوزه سلامت حمایت می شود که توصیف های قوی بین فعالیت فیزیکی و نتایج سلامت از جمله چاقی، دیابت، انواع بیماری های قلبی عروقی، سلامت روانی و مرگ و میر را نشان داده اند. با این حال، استفاده از دستگاه های قابل پوشیدن برای مطالعه سلامت جمعیت دارای محدودیت های مهمی است: مالکیت آنها بسیار کمتر از گوشی های هوشمند است؛ اکثر افراد پس از ۶ ماه استفاده از دستگاه های قابل پوشیدن کار خود را متوقف می کنند. داده های خام معمولاً از دستگاه های قابل پوشیدن در دسترس نیست. این مورد آخر معمولاً محققان را مجبور به اعتماد به معیارهای دستگاه مالکیتی می کند، که نرخ کمی از قابلیت تکرار تحقیقات پزشکی را به کمترین حدی کاهش می دهد و تقریباً احتمال عدم قطعیت را کاهش می دهد.

تشخیص فعالیت انسانی یک فرآیند است که به هدف دسته بندی اعمال انسانی در یک بازه زمانی مشخص

بر اساس اندازه‌گیری‌های گسسته (شتاب، سرعت چرخشی، مختصات جغرافیایی و غیره) انجام شده توسط دستگاه‌های دیجیتال شخصی می‌پردازد. در سال‌های اخیر، این موضوع در جامعه تحقیقات یادگیری ماشین رشد چشمگیری داشته است، بیش از ۴۰۰ مقاله در مورد روش‌های تشخیص فعالیت انسانی با استفاده از داده‌های گوشی‌های هوشمند منتشر شده است. این افزایش قابل توجه نسبت به تعداد اندکی از مقالاتی است که چند سال قبل منتشر شده بودند. با تسهیل جمع‌آوری داده‌ها با استفاده از گوشی‌های هوشمند، تجزیه و تحلیل داده‌های جمع‌آوری شده به عنوان مهم‌ترین مانع در تحقیقات سلامت مشخص می‌شود. برای مقابله با چالش‌های تحلیلی تشخیص فعالیت انسانی، محققان الگوریتم‌های مختلفی را پیشنهاد داده‌اند که اختلاف‌های قابل توجهی در مورد نوع داده‌هایی که استفاده می‌کنند، چگونگی تغییر دادن داده‌های جمع‌آوری شده و روش‌های آماری استفاده شده برای استنباط و یا دسته‌بندی دارند. مطالعات منتشر شده از روش‌های موجود استفاده می‌کنند و روش‌های جدیدی را برای جمع‌آوری، پردازش و دسته‌بندی فعالیت‌های روزمره ارائه می‌دهند. نویسندگان معمولاً در مورد تکنیک‌های فیلترینگ داده و انتخاب ویژگی بحث می‌کنند و دقت دسته‌بندی انواع مختلفی از دستگاه‌های یادگیری ماشین را در گروه‌های مختلفی از فعالیت‌ها، مانند پیاده‌روی، حرکت و تمرین، معمولاً با استفاده از دیتاست‌های مختلف خلاصه می‌کنند.

۲-۱ طرح مسئله

تشخیص فعالیت انسانی یک زمینه مطالعاتی مربوط به تشخیص رفتار افراد بر اساس داده‌های سری زمانی ضبط شده با سنسورها است. بدلیل پیشرفت و گسترش سریع گوشی‌های هوشمند و ساعت‌های هوشمند تعبیه شده با حسگرهای پوشیدنی مثل ژيروسکوپ و شتاب سنج‌ها براحتی می‌توان حرکات انسان را شناسایی کرد. این کار در زمینه‌هایی مانند مراقبت‌های بهداشتی، ردیاب‌های تناسب اندام شخصی و محافظت از افراد سال‌خورده اهمیت زیادی دارد.

مدل‌های تشخیص فعالیت انسانی مبتنی بر گوشی‌های هوشمند می‌توانند با استفاده از الگوریتم‌های یادگیری ماشین کم‌عمق یا عمیق پیاده‌سازی شوند. در الگوریتم‌های یادگیری ماشین کم‌عمق، مهندسی ویژگی مرحله مهمی است تا ویژگی‌های مرتبط استخراج شود. سپس ویژگی‌ها به هر الگوریتم دسته‌بندی منتقل می‌شوند تا انواع مختلفی از فعالیت‌های جسمانی انسان را به طریق کارآمد و صحیح شناسایی کنند. سیگنال‌های حسگری گوشی‌های هوشمند در حالت خام مناسب نیستند، چون به شدت نویزی و

ارتعاشی هستند. بنابراین شناسایی الگوهای ابتدایی با استفاده از این سیگنال‌های خام بسیار دشوار است. بنابراین بدون مهندسی ویژگی‌ها، دسته‌بندی‌ها ناکارآمد هستند و نتایج صحیحی ارائه نمی‌دهند. علاوه بر این، بدون استخراج ویژگی‌های مناسب، دسته‌بندی نمی‌توان فعالیت‌های جسمانی انسانی مشابهی مانند پیاده‌روی و بالا رفتن از پله را شناسایی کند.

علاوه بر این، ویژگی‌های آماری دستی استخراج شده برای رفع مشکل مربوط به موقعیت گوشی هوشمند در زمان جمع‌آوری داده استفاده می‌شوند. بیشتر راه‌حل‌های شناخت فعالیت انسانی وابسته به موقعیت هستند. این بدان معناست که در زمان جمع‌آوری داده، موقعیت گوشی هوشمند ثابت است و دقت دسته‌بندی‌ها بر اساس موقعیت گوشی هوشمند متغیر است. ویژگی‌های دستی استخراج شده توسط موقعیت گوشی هوشمند در زمان جمع‌آوری داده تحت تأثیر قرار نمی‌گیرند. پس از استخراج ویژگی‌های دستی، دسته‌بندی‌های یادگیری ماشین کم‌عمق برای شناسایی انواع مختلفی از فعالیت‌های جسمانی انسان استفاده می‌شوند. بنابراین، الگوریتم‌های یادگیری ماشین کم‌عمق بر ویژگی‌های دستی تکیه دارند. در مقابل، الگوریتم‌های یادگیری عمیق یک گام جلوتر از الگوریتم‌های یادگیری ماشین کم‌عمق هستند، زیرا الگوریتم‌های یادگیری عمیق به طور خودکار و بدون دخالت انسان ویژگی‌های مرتبط را از داده‌های حسگر خام یاد می‌گیرند و همچنین به طور همزمان فعالیت‌های جسمانی انسانی را شناسایی می‌کنند. با استفاده از داده‌های این سنسورهای پوشیدنی می‌توان به صورت روزانه فعالیت‌های مختلف روزانه افراد مثل خوردن، آشامیدن، مسواک زدن و حتی خواب نامعمول را شناسایی، کلاس بندی و آنها را ثبت کرد.

هدف این پروژه پیاده سازی روش های یادگیری عمیق برای شناسایی رفتار افراد بر اساس داده های ژيروسکوپ و شتاب سنج گوشی های هوشمند است. روش های یادگیری عمیق پیاده سازی شده شامل: شبکه کانولوشنی، شبکه حافظه کوتاه مدت ماندگار، شبکه حافظه کوتاه مدت ماندگار دو طرفه و شبکه عمیق کانولوشنی حافظه کوتاه مدت ماندگار است.

فصل دوم

مفاهیم پایه

در این بخش ابتدا به مفاهیم اولیه مورد نیاز برای طراحی یک سیستم تشخیص رفتار انسان بر اساس داده های گوشی های هوشمند می پردازیم. سپس کارهای پیشین انجام شده مربوط به این نوع سیستم ها را مورد مطالعه قرار می دهیم.

۱-۲ معرفی روش های تشخیص فعالیت انسانی

۱-۱-۲ رویکرد یادگیری ماشینی

الگوریتم های یادگیری ماشینی را می توان برای دسته بندی فعالیت های انسانی استفاده کرد. این کار را می توان با استفاده از روش های یادگیری تحت نظارت^۱ و بدون نظارت انجام داد. روش های یادگیری نظارت شده به دلیل نتایج دقیق، بیشتر مورد استفاده قرار می گیرند.

۲-۱-۲ رویکرد یادگیری عمیق

یادگیری عمیق، یادگیری ژرف یا ژرف آموزی یک زیرشاخه از یادگیری ماشین و بر مبنای مجموعه ای از تاگوریتم ها است که در تلاشند تا مفاهیم انتزاعی سطح بالا در دادگان را مدل نمایند که این فرایند را با استفاده از یک گراف عمیق که دارای چندین لایه پردازشی متشکل از چندین لایه تبدیلات خطی و غیرخطی هستند، مدل می کنند. به بیان دیگر پایه آن بر یادگیری نمایش دانش و ویژگی ها در لایه های مدل است [۷]. واژه عمیق به این معنی است که شما با یک شبکه بزرگ عصبی سروکار دارید. این کلمه به تعداد لایه های پنهان در شبکه های عصبی اشاره می کند. شبکه های عصبی سنتی فقط شامل ۲ یا ۳ لایه پنهان هستند، در صورتی که شبکه های عصبی عمیق می توانند تا ۱۵۰ لایه داشته باشند.

۲-۲ معرفی شبکه عصبی و اجزای آن^۲

۱-۲-۲ توضیح شبکه عصبی

شبکه های عصبی سیستم ها و روش های محاسباتی نوین برای یادگیری ماشینی، نمایش دانش و در انتها اعمال دانش بدست آمده در جهت پیش بینی پاسخ های خروجی از سامانه های پیچیده هستند. ایده ی


^۱ Unsupervised

^۲ Artificial Neural network

اصلی ای گونه شبکه ها تا حدودی الهام گرفته از شیوه کارکرد سیستم عصبی زیستی برای پردازش داده ها و اطلاعات به منظور یادگیری و ایجاد دانش می باشد. عنصر کلیدی این ایده، ایجاد ساختارهای جدید برای سامانه پردازش اطلاعات است [۸]. در شبکه عصبی داده های ورودی با عبور از لایه های مختلف و گره های مصنوعی متصل به هم، پردازش می شوند تا در نهایت خروجی مورد انتظار تولید شود.

۲-۲-۲ معرفی اجزای شبکه عصبی مصنوعی

- لایه ورودی: این مفهوم همچنین به عنوان گره های ورودی شناخته می شود، ورودی/اطلاعات دنیای بیرون برای یادگیری و نتیجه گیری در اختیار مدل قرار می گیرد. گره های ورودی، اطلاعات را به لایه بعدی یعنی لایه پنهان منتقل می کنند.
- لایه پنهان: لایه پنهان مجموعه ای از نورون ها است که در آن تمام محاسبات روی داده های ورودی انجام می شود. در یک شبکه عصبی، تعداد زیادی لایه پنهان می تواند وجود داشته باشد. ساده ترین شبکه از یک لایه پنهان تشکیل شده است.
- لایه خروجی: لایه خروجی، همان طور که نام آن نشان می دهد، خروجی/نتیجه مدلی است که از تمامی محاسبات انجام شده به دست می آید. در لایه خروجی می توان گره های منفرد یا چندگانه وجود داشته باشد. اگر مشکل طبقه بندی باینری داشته باشیم، گره خروجی ۱ است، اما در مورد طبقه بندی چند کلاسه، گره های خروجی می توانند بیش از ۱ باشند.



شکل ۲-۱: ساختار یک شبکه عصبی [۱]

۲-۲-۳ تابع فعال سازی^۳

توابع فعال ساز در واقع مانند گیتی هستند که در هر نورون وجود دارد. ورودی این گیت همان ورودی‌های هر نورون در هر لایه است (در وزن‌های متناظر خود ضرب شده‌اند و با مقدار ثابت بایاس جمع شده‌اند) و خروجی آن به لایه‌ی بعدی منتقل می‌شود. تابع فعال ساز تصمیم می‌گیرد هر نورون فعال شود یا نه. اگر از توابع فعال ساز استفاده نکنیم، وزن‌ها و مقدار بایاس فقط یک معادله‌ی خطی را ایجاد می‌کنند. درست است که معادله‌ی خطی خیلی راحت‌تر حل‌شدنی است، اما برای حل مسائل پیچیده نمی‌تواند کمکی به ما کند. در واقع معادلات خطی در یادگیری الگوهای پیچیده‌ی داده‌ی خیلی محدود هستند و یک شبکه‌ی عصبی بدون تابع فعال ساز فقط یک مدل رگرسیون خطی است. به‌طور کلی، شبکه‌های عصبی از توابع فعال‌ساز استفاده می‌کنند تا بتوانند به شبکه در یادگیری داده‌های پیچیده کمک و پیش‌بینی قابل‌قبولی را در خروجی ارائه کنند.

• تابع سیگموئید^۴

این تابع فعال‌سازی غیرخطی، ورودی خود را به مقداری در بازه ۰ تا ۱ تبدیل می‌کند. هرچقدر

^۳ Activation function

^۴ Sigmoid


مقدار ورودی بزرگ‌تر باشد، مقدار خروجی این تابع به عدد ۱ نزدیک‌تر می‌شود. در حالی که اگر مقدار ورودی این تابع خیلی کوچک باشد (عدد منفی)، مقدار خروجی تابع سیگموئید به عدد صفر نزدیک‌تر می‌شود. تابع سیگموئید، تابعی «یکنوا» محسوب می‌شود اما مشتق این تابع، تابع یکنوا نیست.

تابع سیگموئید به عنوان یکی از پرکاربردترین توابع فعالسازی غیرخطی محسوب می‌شود. مزایای استفاده از این تابع به شرح زیر هستند:

□ معمولاً، از این تابع در مدل‌هایی استفاده می‌شود که خروجی مدل، مقداری احتمالاتی است. از آنجا که مقدار احتمال، عددی بین ۰ تا ۱ است، تابع سیگموئید بهترین انتخاب برای محاسبه احتمال محسوب می‌شود.

□ تابع سیگموئید تابعی مشتق‌پذیر به حساب می‌آید و نمودار خروجی این تابع دارای شیب ملایم به شکل S است.

مهم‌ترین محدودیتی که تابع سیگموئید در شبکه‌های عصبی ایجاد می‌کند، مسئله محوشدگی گرادیان است که به دلیل مشتق این تابع اتفاق می‌افتد.



شکل ۲-۲: تابع فعال‌سازی سیگموئید [۲]

• تابع تانژانت هذلولوی^۵

تابع فعال‌سازی تانژانت هذلولوی به اختصار Tanh با تابع فعال‌سازی سیگموئید بسیار شباهت دارد و منحنی این تابع به S شبیه است. تابع تانژانت هذلولوی تابعی یکنواخت محسوب می‌شد اما


^۵Hyperbolic Tangent

مشتق آن، تابع یکنواخت نیست. تنها تفاوت این تابع با تابع سیگموئید، بازه خروجی این تابع است که مقدار ورودی خود را به محدوده بین -1 تا 1 نگاشت می‌کند. هرچقدر مقدار ورودی این تابع بزرگ‌تر باشد، مقدار خروجی تابع به عدد 1 نزدیک‌تر خواهد بود و هرچقدر مقدار ورودی این تابع کوچک‌تر باشد، مقدار خروجی تابع به عدد -1 نزدیک‌تر می‌شود. مزایای این تابع به شرح زیر است:

□ تابع تانژانت تابعی مشتق‌پذیر است.

□ خروجی این تابع در مرکز منحنی برابر صفر است. به این ترتیب، به راحتی می‌توان مقادیر خروجی را به صورت مثبت، منفی و خنثی تقسیم کرد.

مشکل تابع فعال‌سازی تانژانت مشابه مشکل تابع سیگموئید است و زمانی که تعداد لایه‌های پنهان شبکه عصبی زیاد باشند، در یادگیری شبکه عصبی و مرحله انتشار رو به عقب، مسئله محوشدگی گرادیان رخ می‌دهد.



شکل ۲-۳: تابع فعال‌سازی تانژانت هذلولوی [۲]

• تابع سافت‌مکس^۶

این تابع فعال‌ساز از جمله توابع فعال‌سازی است که در طبقه‌بندی‌های چند کلاسه استفاده می‌شود. زمانی که احتیاج داشته باشیم در خروجی احتمال عضویت بیشتر از دو کلاس را پیش‌بینی کنیم، می‌توانیم به سراغ این تابع برویم. تابع سافت‌مکس تمامی مقادیر یک بردار به طول K را به

SoftMax^۶

بازه‌ی صفر تا یک می‌برد، به طوری که جمع تمامی مقادیر این بردار با هم یک می‌شود [۹]. این تابع برای نورون‌های لایه خروجی استفاده می‌شود. زیرا در شبکه‌های عصبی در آخرین لایه (خروجی) به طبقه بندی ورودی‌ها در کلاس‌های مختلف نیاز داریم.

• تابع فعال‌سازی یکسوساز^۷

اگرچه این تابع، ظاهری شبیه به تابع خطی دارد، اما این تابع مشتق‌پذیر است و از آن می‌توان در مرحله انتشار رو به عقب استفاده کرد. این تابع تمامی گره‌ها را همزمان فعال نمی‌کند. به عبارتی، گره‌ها زمانی غیرفعال هستند که مقدار ورودی این تابع کمتر از صفر باشد. به عبارتی، براساس نمودار این تابع، چنانچه ورودی تابع بزرگتر از صفر باشد، خروجی تابع برابر با ورودی تابع و اگر ورودی تابع، مقداری کمتر از صفر باشد، خروجی تابع برابر با صفر است. تابع یکسوساز و مشتق آن یکنواخت هستند. مزایای تابع فعال‌سازی یکسوساز:

□ تابع یکسوساز تابعی مشتق‌پذیر است.

□ به دلیل ویژگی خطی بودن و غیر اشباع‌کنندگی^۸ تابع، همگرایی الگوریتم سریع‌تر اتفاق می‌افتد. بدین ترتیب، مدل به زمان کمتری برای یادگیری نیاز دارد.

□ از آنجا که این تابع فقط تعدادی از گره‌ها را فعال می‌کند، به لحاظ محاسباتی از کارایی بهتری نسبت به سایر توابع فعال‌سازی در شبکه‌های عصبی برخوردار است.

□ تابع یکسوساز مشکل محوشدگی^۹ گرادیان توابع سیگموئید و تانژانت را ندارد؛ زیرا محدوده مثبت خطی این تابع به گرادیان‌ها اجازه می‌دهد در مسیر فعال گره‌ها در جریان باشند. همچنین، این تابع محدودیتی برای ماکسیمم مقدار ورودی ایجاد نمی‌کند.


محدودیت مهمی که تابع یکسوساز با آن مواجه می‌شود، مسئله زوال^۹ تابع یکسوساز است. این حالت زمانی اتفاق می‌افتد که خروجی چندین تابع یکسوساز به صورت متوالی برابر با صفر باشد. در حالتی که اکثر خروجی‌های توابع برابر با صفر شوند، در مرحله انتشار رو به عقب، گرادیان‌ها در طول شبکه جریان پیدا نمی‌کنند و به این ترتیب، وزن‌های شبکه به روزرسانی نمی‌شوند. بنابراین،

^۷ RELUs

^۸ non-saturating

^۹ Dying

در این حالت، بخش بزرگی از شبکه عصبی غیرفعال باقی می‌ماند و یادگیری شبکه به درستی انجام نمی‌شود.



شکل ۲-۴: تابع فعال‌ساز یکسوساز [۲]

۴-۲-۲ تابع بهینه‌سازی

انتخاب الگوریتم بهینه‌سازی مناسب برای مدل یادگیری عمیق بسیار مهم است و تاثیر زیادی روی زمان رسیدن به نتیجه مطلوب دارد.

الگوریتم بهینه‌سازی آدام^{۱۰}

الگوریتم آدام یک الگوریتم بهینه‌سازی است که می‌توان از آن به جای روش گرادیان کاهشی تصادفی^{۱۱} کلاسیک برای به‌روزرسانی وزن‌های شبکه بر اساس تکرار در داده‌های آموزشی استفاده کرد. الگوریتم آدام را می‌توان به عنوان ترکیبی از RMSprop و گرادیان نزولی تصادفی با گشتاور در نظر گرفت.

مزیت‌های الگوریتم بهینه‌سازی آدام

مزیت‌های جالب توجه استفاده از این الگوریتم در مسائل بهینه‌سازی غیر محدب شامل موارد زیر است:

- این الگوریتم به آسانی پیاده‌سازی می‌شود

- به لحاظ محاسباتی بهینه است

^{۱۰}Adam optimizer

^{۱۱}Stochastic Gradient Descent | SGD

- آدام به حافظه کمی نیاز دارد
- الگوریتم بهینه سازی آدام در برابر مقیاس دهی مجدد قطری گرادیان ها تغییر نمی کند و به آن ها وابستگی ندارد
- ابرپارامترها ^{۱۲} در الگوریتم بهینه سازی آدام دارای تفسیر بصری هستند و معمولاً به تنظیم پارامتر اندکی نیاز دارند.

چگونگی کارکرد الگوریتم بهینه سازی آدام

الگوریتم آدام با گرادیان کاهشی کلاسیک متفاوت است. گرادیان کاهشی تصادفی یک نرخ یادگیری واحد (به نام آلفا) را برای تمام به روزرسانی وزن ها استفاده می کند و این نرخ یادگیری در طول فرآیند آموزش مدل تغییر نمی کند. نرخ یادگیری در الگوریتم بهینه سازی آدام برای هر یک از وزن های شبکه (پارامترها) حفظ می شود و این نرخ با شروع فرآیند یادگیری به صورت جداگانه تطبیق داده می شود. در روش بهینه سازی آدام، هر یک از نرخ های یادگیری برای پارامتر های مختلف از گشتاورهای اول و دوم گرادیان ها محاسبه می شوند. الگوریتم آدام به عنوان نسخه ترکیبی مزیت های دو الگوریتم تعمیم یافته دیگر گرادیان کاهشی تصادفی توصیف می شود [۱۰].

۵-۲-۲ تنظیم کننده ^{۱۳}

یک مدل حداقل مربعات استاندارد مقداری واریانس در خود دارد، یعنی این مدل به خوبی برای یک مجموعه داده متفاوت از داده های آموزشی آن تعمیم داده نمی شود. تنظیم کننده، به طور قابل توجهی واریانس مدل را کاهش می دهد، بدون افزایش قابل توجه در بایاس آن. بنابراین پارامتر تنظیم لامبدا که در تکنیک های رگولاریزاسیون که در بالا توضیح داده شد استفاده می شود، تاثیر بر بایاس و واریانس را کنترل می کند. وقتی مقدار لامبدا بالا می رود، مقدار ضرایب را کاهش داده و در نتیجه واریانس را کاهش می دهد. تا یک نقطه، این افزایش در لامبدا مفید است زیرا فقط واریانس را کاهش می دهد (بنابراین از بیش برازش اجتناب می کند) بدون این که هیچ ویژگی مهمی را در داده ها از دست بدهد. اما بعد از یک مقدار مشخص، مدل شروع به از دست دادن ویژگی های مهم می کند، که منجر به افزایش بایاس در مدل و در نتیجه برازش نامناسب می شود. بنابراین مقدار لامبدا باید به دقت انتخاب شود [۱۱].

^{۱۲} Hyper-Parameters

^{۱۳} Regularization

تنظیم کننده L2

نوعی از تنظیم کننده که وزن‌ها را به نسبت مجموع مربعات آن‌ها کاهش می‌دهد. نظم‌دهی L2 تلاش می‌کند تا وزن‌های استثناء (آن‌هایی که مقدار مثبت بسیار بالا یا مقدار منفی بسیار پایین دارند) به صفر نزدیک شوند اما دقیقاً صفر نشوند. این نظم‌دهی همیشه قدرت تعمیم مدل‌های خطی را بالا می‌برد.

تنظیم کننده L1

نوعی از تنظیم کننده که وزن‌ها را به نسبت مجموع مقدار قدر مطلق آن‌ها کاهش می‌دهد. در مدل‌هایی که بر ویژگی‌های پراکنده تکیه دارند، تنظیم کننده L1 کمک می‌کند تا وزن ویژگی‌های نامربوط یا کم‌ارتباط به دقیقاً ۰ برسد. این کار آن ویژگی‌ها را از مدل حذف می‌کند [۱۲].

۶-۲-۲ توضیح یادگیری در شبکه‌های عصبی

در مباحث مربوط به شبکه‌های عصبی، قواعد یادگیری، رویه‌ای برای اصلاح وزن‌ها و بایاس‌ها تعریف می‌کنند. قاعده یادگیری در راستای آموزش شبکه برای انجام کار خاصی مورد استفاده قرار می‌گیرد. در قاعده یادگیری با نظارت از مجموعه‌ای از نمونه‌های آموزشی استفاده می‌کنیم که شبکه را آموزش می‌دهند. در هر زوج مرتب x_i ورودی شبکه و y_i به عنوان خروجی، زمانیکه ورودی به شبکه اعمال می‌شود، خروجی با هدف مقایسه می‌شود. سپس بر طبق قواعد یادگیری برای تنظیم وزن‌ها و بایاس‌ها تغییرات لازم با استفاده از الگوریتم‌های گرادیان کاهشی و انتشار رو به عقب اعمال می‌گردد تا خروجی شبکه به هدف مورد نظر نزدیک‌تر شود.


۷-۲-۲ توضیح گرادیان کاهشی^{۱۴}

گرادیان کاهشی الگوریتم بهینه‌سازی مرتبه اول از نوع الگوریتم‌های تکرار شونده است. برای یافتن کمینه محلی یک تابع با استفاده از این الگوریتم، گام‌هایی متناسب با منفی گرادیان (یا گرادیان تخمینی) تابع در محل فعلی برداشته خواهد شد [۱۳].

فرض می‌کنیم تابعی چند متغیره به اسم $F(x)$ داریم که مشتق‌پذیر است و هدف یافتن یک نقطه x است که تابع را به حداقل ممکن برساند. برای نقطه a جهتی که مقدار تابع با بیشترین شیب به صورت

Gradient Descent^{۱۴}

محلی کاهش پیدا می‌کند، خلاف جهت گرادیان تابع در آن نقطه است. الگوریتم گرادیان کاهشی به صورت متناوب هر بار به اندازه نرخ یادگیری^{۱۵} در خلاف جهت گرادیان حرکت می‌کند. نرخ یادگیری اندازه مرحله‌ای است که برای رسیدن به حداقل انجام می‌شود. این مقدار معمولاً یک مقدار کوچک است و بر اساس رفتار تابع هزینه ارزیابی و به روز می‌شود. نرخ بالای یادگیری منجر به گام‌های بزرگتر می‌شود، اما خطر فراتر رفتن از حداقل را دارد. برعکس، نرخ یادگیری پایین دارای اندازه گام‌های کوچکی است در حالی که مزیت دقت بیشتر را دارد^[۱۴].



شکل ۲-۵: تفاوت نرخ یادگیری کوچک و بزرگ [۳]

سه نوع گرادیان کاهشی وجود دارد.

• ^{۱۶}گرادیان کاهشی دسته‌ای

گرادیان کاهشی دسته‌ای خطا را برای هر نقطه در یک مجموعه آموزشی جمع می‌کند و مدل را تنها پس از ارزیابی تمام نمونه‌های آموزشی به روز می‌کند. از این فرآیند به عنوان یک دوره آموزشی^{۱۷} یاد می‌شود. در حالی که این دسته‌بندی کارایی محاسباتی را فراهم می‌کند، می‌تواند زمان پردازش طولانی برای مجموعه داده‌های آموزشی بزرگ داشته باشد، زیرا باید تمام داده‌ها را در حافظه ذخیره کند. گرادیان کاهشی دسته‌ای نیز معمولاً هم‌گرایی پایدار ایجاد می‌کند، اما گاهی اوقات این نقطه هم‌گرایی ایده‌آل‌ترین نقطه نیست و حداقل محلی^{۱۸} را در مقابل نقطه جهانی^{۱۹} پیدا می‌کند^[۱۳].

^{۱۵} Learning rate

^{۱۶} Batch gradient descent

^{۱۷} epoch

^{۱۸} Local

^{۱۹} Global

• گرادیان کاهشی تصادفی^{۲۰}

گرادیان کاهشی تصادفی یک دوره آموزشی را برای هر نمونه در مجموعه داده اجرا می‌کند و پارامترهای هر نمونه آموزشی را یکی یکی به روز می‌کند. از آنجایی که فقط نیاز به نگه داشتن یک نمونه آموزشی دارد، ذخیره آنها در حافظه آسان تر است. در حالی که این به روزرسانی‌های مکرر می‌توانند جزئیات و سرعت بیشتری را ارائه دهند، در مقایسه با گرادیان کاهشی دسته‌ای، می‌تواند منجر به کاهش کارایی محاسباتی شود. به روزرسانی‌های مکرر آن می‌تواند منجر به گرادیان‌های نویزی شود، اما این می‌تواند برای فرار از حداقل محلی و یافتن حداقل جهانی مقید باشد [۱۳].

• گرادیان کاهشی دسته‌ای کوچک^{۲۱}

گرادیان کاهشی دسته‌ای کوچک مفاهیمی را از هر دو گرادیان کاهشی تصادفی و گرادیان کاهشی دسته‌ای ترکیب می‌کند. این روش مجموعه داده آموزشی را به اندازه‌های دسته‌ای ک.چک تقسیم می‌کند و به روزرسانی را در هر یک از آن دسته‌ها انجام می‌دهد. این رویکرد تعادلی بین کارایی محاسباتی گرادیان کاهشی تصادفی و گرادیان کاهشی دسته‌ای ایجاد می‌کند [۱۳]. اندازه‌های دسته معمولی بین ۵۰ تا ۲۵۶ است، اما مانند هر تکنیک یادگیری ماشین دیگری، قانون واضحی وجود ندارد زیرا برای کاربردهای مختلف متفاوت است.

۸-۲-۲ توضیح انتشار رو به عقب^{۲۲}

عملکرد شبکه‌های عصبی بر پایه تکرار است و یکی از الگوریتم‌های پر کاربرد در این زمینه الگوریتم انتشار رو به عقب است. با به کار بردن این الگوریتم در هر تکرار دو مرحله خواهیم داشت. مرحله اول هنگامی که شبکه‌های عصبی مصنوعی شکل می‌گیرند، مقادیر وزن‌ها به صورت تصادفی تعیین می‌شوند. کاربر وزن‌های تصادفی را تعیین می‌کند زیرا از مقادیر صحیح آگاه نیست. پس از تعیین وزن‌ها، سپس حرکت رو به جلو را خواهیم داشت. در این قسمت با انجام عملیات ضرب داده‌های ورودی در وزن‌ها پ سپس جمع کردن آن با بایاس شبکه پیش می‌رود. در نهایت در همان مرحله به یک مقدار خروجی خواهیم رسید که ممکن است با خروجی واقعی اختلاف داشته باشد، بعد از این که شبکه متوجه خطا با توجه به وزن‌ها و بایاس شد وارد قسمت دوم این مرحله می‌شویم. در این قسمت شبکه به عقب بر می‌گردد و به

^{۲۰} Stochastic gradient descent

^{۲۱} Mini Batch gradient descent

^{۲۲} Back Propagation

طور مجدد وزن‌ها و بایاس را محاسبه می‌کند. این تغییر به سمتی پیش می‌رود که میزان خطا کاهش یابد و مقدار پیش‌بینی شده با مقدار واقعی تفاوت کمتری داشته باشد [۱۵].

۹-۲-۲ تعریف تابع هزینه^{۲۳}

در الگوریتم بهینه‌سازی، خطای وضعیت فعلی مدل باید به طور مکرر تخمین زده شود. به همین خاطر به یک تابع خطا نیاز داریم، این تابع می‌تواند برای تخمین از دست دادن مدل استفاده شود تا وزن‌ها برای کاهش خطا در ارزیابی بعدی به روز شوند.

تابع هزینه، تفاوت بین خروجی واقعی و خروجی پیش‌بینی شده را در موقعیت فعلی خود اندازه‌گیری می‌کند. این کار با ارائه بازخورد به مدل، کارایی مدل یادگیری ماشین را بهبود می‌بخشد تا بتواند پارامترها را برای به حداقل رساندن خطا و یافتن حداقل محلی یا جهانی تنظیم کند.

معرفی آنتروپی متقاطع^{۲۴}

تابع ضرر آنتروپی متقاطع عملکرد یک مدل طبقه‌بندی را اندازه‌گیری می‌کند که خروجی آن یک مقدار احتمال بین ۰ و ۱ است. مقدار تابع آنتروپی متقاطع با فاصله گرفتن احتمال پیش‌بینی شده از برچسب واقعی افزایش می‌یابد. نحوه محاسبه این تابع در زیر آمده است:

$$crosss - entropy = \sum_{i=1}^{number-of-classes} y_i \log_{\cdot} \hat{y}_i$$

تعریف محو شدن گرادیان

همانطور که الگوریتم انتشار رو به عقب از لایه خروجی به سمت لایه ورودی به سمت پایین (یا به عقب) پیش می‌رود، گرادیان‌ها اغلب کوچکتر و کوچکتر می‌شوند و به صفر نزدیک می‌شوند که در نهایت وزن لایه‌های اولیه یا پایین تقریباً بدون تغییر باقی می‌ماند. در نتیجه، کاهش گرادیان هرگز به حد مطلوب همگرا نمی‌شود. این به عنوان مشکل محو شدن گرادیان شناخته می‌شود. مشکل محو شدن گرادیان معمولاً زمانی رخ می‌دهد که از توابع فعال‌سازی سیگموئید یا تانژانت هذلولی در لایه پنهان استفاده می‌کنیم. همچنین این مشکل در شبکه‌های عصبی بازگشتی^{۲۵} نیز وجود دارد [۱۶].

^{۲۳} Cost function

^{۲۴} Cross Entropy

^{۲۵} Recurrent Neural Network

منفجر شدن^{۲۶} گرادیان

در برخی موارد، با پیشرفت الگوریتم انتشار رو به عقب، گرادیان‌ها بزرگتر و بزرگتر می‌شوند. این به نوبه خود باعث می‌شود که در به روزرسانی، وزن‌ها مقادیر بسیار بزرگی بگیرند و باعث واگرایی شیب نزولی می‌شود. این به عنوان مشکل گرادیان انفجاری شناخته می‌شود. گاهی اوقات ممکن است پارامترها آنقدر بزرگ شوند که سرریز شوند و دیگر نتواند به روز شوند [۱۶].

بیش‌برازش^{۲۷}

بیش‌برازش یکی از خطاهای مدل‌سازی در علم داده است. این خطا هنگامی اتفاق می‌افتد که مدل ویژگی‌های داده‌های آموزشی را به‌جای یادگیری، حفظ کرده باشد، یعنی بیش از حد روی آن آموزش دیده باشد. در نتیجه، این مدل فقط در مجموعه‌ی داده‌های آموزشی مفید خواهد بود و نه در مجموعه‌ی داده‌های دیگر که هنوز آن‌ها را ندیده است [۱۷].

هنگامی که الگوریتم‌های یادگیری ماشین ساخته می‌شوند، از مجموعه داده‌های نمونه برای آموزش مدل استفاده می‌کنند. با این حال، زمانی که مدل برای مدت طولانی روی داده‌های نمونه تمرین می‌کند یا زمانی که مدل خیلی پیچیده است، می‌تواند شروع به یادگیری نویز یا اطلاعات نامربوط در مجموعه داده کند. وقتی مدل نویز را به خاطر می‌سپارد و خیلی نزدیک به مجموعه آموزشی منطبق می‌شود، مدل بیش از حد برازش می‌شود و نمی‌تواند به خوبی به داده‌های جدید تعمیم دهد. اگر یک مدل نتواند به خوبی به داده‌های جدید تعمیم دهد، آنگاه نمی‌تواند وظایف طبقه‌بندی یا پیش‌بینی را که برای آن در نظر گرفته شده است انجام دهد. نرخ خطای پایین و واریانس بالا شاخص‌های خوبی برای تشخیص برایش بیش از حد مناسب هستند. از جمله دلایلی که بیش‌برازش اتفاق می‌افتد:

- مدل بیش از حد پیچیده است

- تعداد ویژگی‌های داده‌های ما بیشتر یا برابر با تعداد داده است

- حجم داده بسیار کم است

- داده پیش‌پردازش نشده تمیز نیست

^{۲۶} Explode

^{۲۷} Overfit

روش‌های زیادی برای جلوگیری از بیش برآزش وجود دارد که در ادامه به آن می‌پردازیم.

• منظم سازی^{۲۸}

در این استراتژی، عبارتی به تابع هزینه اضافه می‌شود تا جریمه‌ای بر وزن شبکه‌های بزرگ برای کاهش بیش برآزش اعمال شود. بسته به تکنیک، برخی از پارامترهای وزن ممکن است برابر یا صفر تخمین زده شوند [۱۲]. از رایج ترین انواع منظم‌سازی می‌توان به $L1$ ، $L2$ اشاره کرد. اینها تابع هزینه عمومی را با افزودن عبارت دیگری به نام اصطلاح منظم‌سازی به روز می‌کنند. منظم سازی نوع $L1$ با فرمول زیر محاسبه می‌شود:

$$cost - function = Loss + \lambda + \sum ||W||$$

در اینجا لامبدا پارامتر منظم سازی و هایپرپارامتری^{۲۹} است که مقدار آن برای گرفتن نتایج بهتر بهینه می‌شود.

منظم سازی نوی $L2$ به صورت زیر محاسبه می‌شود :

$$cost - function = Loss + \lambda + \sum ||W||^2$$

به طور شهودی وزن‌های کوچکتر تاثیر نورون‌های پنهان را کاهش می‌دهند. در آن صورت، آن نورون‌های پنهان نادیده گرفته می‌شوند و پیچیدگی کلی شبکه عصبی کاهش می‌یابد.

هنگام انتخاب عبارت منظم سازی هدف ایجاد تعادل مناسب بین پیچیدگی کم مدل و دقت است. اگر مقدار لامبدا بیش از حد بالا باشد، مدل ساده خواهد بود، اما در معرض خطر عدم تناسب داده‌ها هستیم و مدل به اندازه کافی در مورد داده‌های آموزشی یاد نمی‌گیرد تا بتواند پیش‌بینی‌های مفیدی انجام دهد.

اگر مقدار لامبدا خیلی کم باشد، مدل پیچیده‌تر می‌شود و بیش از حد در مورد ویژگی‌های داده‌های آموزشی یاد می‌گیرد و نمی‌تواند به داده‌های جدید تعمیم دهد.

^{۲۸} Regularization
^{۲۹} Hyperparameter

حذف تصادفی^{۳۰}

حذف تصادفی یک روش منظم سازی است که در آن مجموعه خاصی از نورون‌ها به طور تصادفی نادیده گرفته می‌شوند. از نظر فنی تر در هر مرحله از آموزش نورون‌هایی با احتمال $1-p$ از شبکه حذف شده و نورون‌هایی با احتمال p نگه داشته می‌شوند به طوری که یک شبکه کاهش یافته باقی می‌ماند [۱۷].

این روش در مرحله تست انجام نمی‌شود زیرا در مرحله تست نمی‌خواهیم نویز اضافه شود و بخشی از حدس‌هایمان رندم صورت بگیرد.

کم‌برازش^{۳۱}

کم‌برازش سناریویی در علم داده است که در آن یک مدل قادر به ثبت دقیق رابطه بین متغیرهای ورودی و خروجی نیست و نرخ خطای بالایی هم در مجموعه آموزشی و هم در داده‌های دیده نشده ایجاد می‌کند. زمانی اتفاق می‌افتد که یک مدل خیلی ساده باشد، که می‌تواند نتیجه نیاز یک مدل به زمان آموزش بیشتر، ویژگی‌های ورودی بیشتر یا منظم‌سازی کمتر باشد [۱۷].

کم‌برازش می‌تواند به دلایل زیر رخ دهد:

□ مدل بیش از حد ساده است

□ داده‌های آموزش تمیز نیستند و دارای نویز هستند

□ تعداد داده آموزشی کافی نیست

چندین روش برای جلوگیری از بیش‌برازش وجود دارد که عبارتند از:

□ کاهش منظم‌سازی

□ افزایش ویژگی‌ها

□ افزایش زمان آموزش

^{۳۰} Drop Out

^{۳۱} Underfit

۳-۲ معرفی کلی شبکه‌های عصبی عمیق

در این بخش به معرفی کلی شبکه‌های عصبی عمیق می‌پردازیم. این شبکه‌ها عبارتند از: شبکه عصبی کانولوشنی، شبکه عصبی بازگشتی، شبکه حافظه کوتاه مدت ماندگار، شبکه حافظه کوتاه مدت ماندگار دو طرفه و شبکه کانولوشنی حافظه کوتاه مدت ماندگار دو طرفه

۱-۳-۲ شبکه عصبی کانولوشنی^{۳۲}

شبکه‌های عصبی کانولوشنی زیر مجموعه یادگیری ماشین و قلب یادگیری عمیق هستند. کاربرد اصلی این شبکه‌ها برای پردازش تصویر است و معمولاً برای انجام محاسبات به واحد پردازش گرافیکی نیاز دارند. شبکه‌های عصبی کانولوشنی^{۳۳} نسخه‌های منظم پرسپترون‌های چندلایه هستند [۱۸].

مهم‌ترین ویژگی مدل لایه کانولوشنی این است که می‌توان مستقیم از داده‌های سری زمانی استفاده کرد و نیازی به انجام مرحله استخراج ویژگی‌ها از داده ندارد [۱۹].

یک شبکه عصبی کانولوشنی از یک لایه ورودی، لایه‌های پنهان و یک لایه خروجی تشکیل شده است. در هر شبکه عصبی پیشخور، هر لایه میانی پنهان نامیده می‌شود، زیرا ورودی و خروجی آنها توسط تابع فعال‌سازی و پیچیدگی نهایی پوشانده می‌شود. در یک شبکه عصبی کانولوشنی، لایه‌های پنهان شامل لایه‌هایی هستند که عملیات پیچش^{۳۴} را انجام می‌دهند.

معمولاً این شامل یک لایه است که حاصل ضرب نقطه‌ای که پیچش را با ماتریس ورودی لایه انجام می‌دهد. شبکه عصبی کانولوشنی با هر لایه پیچیدگی خود را افزایش می‌دهد و بخش‌های بیشتری از ورودی را شناسایی می‌کند. لایه‌های قبلی بر روی ویژگی‌های ساده تمرکز می‌کنند. همانطور که داده‌ها در لایه‌های شبکه عصبی کانولوشنی پیشرفت می‌کنند، شروع به تشخیص عناصر بزرگتر می‌کند تا اینکه در نهایت ورودی مورد نظر را شناسایی می‌کنند.

لایه‌های یک شبکه عصبی کانولوشنی عبارت‌اند از: لایه کانولوشن، لایه ادغام^{۳۵} و لایه کاملاً متصل^{۳۶}

CNN^{۳۲}

Multi-Layer Perceptron^{۳۳}

Convolve^{۳۴}

Pooling^{۳۵}

Fully connected^{۳۶}

لایه کانولوشن

لایه‌های پیچشی یک عمل پیچش را روی ورودی اعمال می‌کنند، سپس نتیجه را به لایه بعدی می‌دهند. این پیچش در واقع پاسخ یک تک‌نورون را به یک تحریک دیداری شبیه‌سازی می‌کند [۱۸].

هر نورون پیچشی داده‌ها را تنها برای ناحیه پذیرش خودش پردازش می‌کند. مشبک‌کردن به شبکه‌های پیچشی این اجازه را می‌دهد که انتقال، دوران یا اعوجاج ورودی را تصحیح کنند.

اگرچه شبکه‌های عصبی پیش‌خور کاملاً همبند می‌توانند برای یادگیری ویژگی‌ها و طبقه‌بندی داده به کار روند، این معماری در کاربرد برای تصاویر به کار نمی‌رود. در این حالت حتی برای یک شبکه کم‌عمق تعداد بسیار زیادی نورون لازم است. عمل پیچش یک راه‌حل برای این شرایط است که تعداد پارامترهای آزاد را به عمیق‌تر کردن شبکه کاهش می‌دهد. [۲۰].

لایه ادغام

لایه‌های ادغام^{۳۷}: شبکه‌های عصبی پیچشی ممکن است شامل لایه‌های ادغام محلی یا سراسری باشند که خروجی‌های خوشه‌های نورونی در یک لایه را در یک تک‌نورون در لایه بعدی ترکیب می‌کند [۲۱]. به عنوان مثال روش حداکثر تجمع^{۳۸} حداکثر مقدار بین خوشه‌های نورونی در لایه پیشین استفاده می‌کند.

مثال دیگر میانگین تجمع^{۳۹} است که از مقدار میانگین خوشه‌های نورونی در لایه پیشین استفاده می‌کند.

لایه کاملاً متصل

لایه‌های کاملاً متصل هر نورون در یک لایه را به هر نورون در لایه دیگر متصل می‌کنند. این همان شبکه عصبی پرسپترون چند لایه سنتی است. این لایه وظیفه دسته‌بندی بر اساس ویژگی‌های استخراج شده از مرحله قبل و با استفاده از تابع فعال‌سازی سافت‌مکس انجام می‌دهد.

^{۳۷} Pooling layer

^{۳۸} Max pooling

^{۳۹} Average pooling

۲-۳-۲ شبکه عصبی بازگشتی^{۴۰}

شبکه عصبی بازگشتی نوع خاصی از شبکه عصبی مصنوعی است که برای کار برای داده‌های سری زمانی یا داده‌هایی که شامل دنباله‌ها هستند، سازگار شده است [۲۲].

درواقع نوعی شبکه عصبی است که حافظه‌ی داخلی دارد. به عبارت دیگر این یک شبکه‌ی عصبی معمولی است که در ساختارش حلقه‌ای دارد که از طریق آن در هر گام^{۴۱} خروجی گام قبلی به همراه ورودی جدید به شبکه وارد می‌شود. این حلقه به شبکه کمک می‌کند تا اطلاعات قبلی را در کنار اطلاعات جدید داشته باشد و بتواند براساس این اطلاعات خروجی مدنظر را به ما بدهد. این ویژگی شبکه‌ی عصبی بازگشتی این امکان را می‌دهد که بتوانیم با داده‌های ترتیبی^{۴۲} کار کنیم.

شبکه‌های عصبی پیشخور معمولی فقط برای نقاط داده‌ای در نظر گرفته شده‌اند که مستقل از یکدیگر هستند. با این حال، اگر داده‌ها در یک دنباله به گونه‌ای باشد که یک نقطه داده به نقطه داده قبلی بستگی داشته باشد، باید شبکه عصبی را تغییر دهیم تا وابستگی‌های بین این نقاط داده را ترکیب کنیم. این شبکه‌ها مفهوم حافظه را دارند که به آنها کمک می‌کند وضعیت‌ها یا اطلاعات ورودی‌های قبلی را برای تولید خروجی بعدی دنباله ذخیره کنند.

در شبکه‌های پیشخور ورودی فقط در یک جهت از لایه ورودی، به لایه‌های مخفی و سپس به لایه خروجی حرکت می‌کند و داده‌های قبلی به حافظه سپرده نمی‌شوند. این شبکه‌های عصبی اصلاً ورودیشان را به یاد نمی‌آورند و در پیش‌بینی آنچه در ادامه رخ خواهد داد چندان موفق عمل نمی‌کنند. در واقع، به این علت که شبکه عصبی پیشخور فقط ورودی حال حاضر را در نظر می‌گیرد، هیچ درکی از ترتیب زمانی اتفاقات ندارد.

شبکه‌های عصبی بازگشتی یک لایه بازخورد دارند که در آن خروجی شبکه به همراه ورودی بعدی، به شبکه بازگردانده می‌شود. شبکه عصبی بازگشتی می‌تواند به علت داشتن حافظه داخلی، ورودی قبلی خود را به خاطر بسپارد و از این حافظه برای پردازش دنبال‌هایی از ورودی‌ها استفاده کند. به بیان ساده، شبکه‌های عصبی بازگشتی شامل یک حلقه بازگشتی هستند که موجب می‌شود اطلاعاتی را که از لحظات قبلی بدست آورده‌ایم از بین نروند و در شبکه باقی بمانند [۲۳].


^{۴۰}RNN^{۴۱}step^{۴۲}sequential data

معایب شبکه ی عصبی بازگشتی

این شبکه در مسائلی که نیاز باشد حافظه ی بلند مدت داشته باشیم نمی تواند خیلی خوب عمل کند. در واقع هر قدر فاصله ی بین ورودی^{۴۳} و داده های قبلی بیشتر باشد، شبکه ی عصبی بازگشتی توانایی یادگیری آنها را از دست می دهد. پس بطور کلی می توانیم بگوییم این شبکه حافظه ی کوتاه مدت خوبی دارد اما حافظه ی بلند مدت خوبی ندارد. دلیل نداشتن حافظه ی بلند مدت خوب مفهومی به نام محوشدگی گرادیان^{۴۴} است [۲۴].

۳-۳-۲ شبکه عصبی حافظه کوتاه مدت ماندگار^{۴۵}

شبکه ی حافظه کوتاه مدت ماندگار نوع خاصی از شبکه ی عصبی بازگشتی است که مشکل حافظه ی بلند مدت شبکه ی عصبی بازگشتی را حل می کند. شبکه ی حافظه کوتاه مدت ماندگار سازوکارهایی داخلی به اسم گیت^{۴۶} دارد. این گیت ها جریان اطلاعات را کنترل می کنند. علاوه بر آن مشخص می کنند چه داده هایی در توالی مهم هستند و باید هم چنان حفظ شوند و چه داده هایی باید حذف شوند. به این شکل، شبکه ی اطلاعات مهم را در طول زنجیره ی توالی عبور می دهد تا خروجی مدنظر را داشته باشیم. در شکل پایین ساختار یک شبکه ی عصبی حافظه کوتاه مدت ماندگار را می بینیم:



شکل ۲-۶: ساختار شبکه عصبی حافظه کوتاه مدت ماندگار [۴]

input^{۴۳}
Vanishing Gradient^{۴۴}
LSTM^{۴۵}
Gate^{۴۶}

مفهوم اصلی شبکه‌ی حافظه کوتاه مدت ماندگار

مفهوم اصلی شبکه‌ی شبکه حافظه کوتاه مدت ماندگار همان وضعیت سلول ^{۴۷} و گیت‌های همراهش است. در واقع cell state مانند آزاده‌ای عمل می‌کند که اطلاعات را در طول زنجیره‌ی توالی جلو می‌برد. می‌توانیم به وضعیت سلول به عنوان حافظه‌ی شبکه نگاه کنیم. گیت‌ها اطلاعات را در وضعیت سلول به‌روز نگه می‌دارند. این گیت‌ها شبکه‌های عصبی مختلفی هستند که تصمیم می‌گیرند چه اطلاعاتی به وضعیت سلول وارد بشوند. این این گیت‌ها در طول آموزش شبکه یاد می‌گیرند چه اطلاعاتی باید حفظ یا فراموش شوند.

از تابع فعال‌ساز تانژانت هایپربولیک برای تعدیل کردن مقدار خروجی شبکه استفاده می‌شود. خروجی این تابع بین ۱- و ۱+ است.

یکی دیگر از توابع فعال‌ساز تابع سیگموئید ^{۴۸} است. این تابع مقادیر را میان بازه‌ی صفر تا ۱ قرار می‌دهد. از این تابع در زمان بروزرسانی و یا فراموش کردن داده استفاده می‌کنیم. چون هر عددی که در صفر ضرب شود نتیجه صفر می‌شود و این یعنی آن داده باید فراموش شود و هر عددی که در ۱ ضرب شود برابر خودش می‌شود و این یعنی آن داده باید حفظ شود. به این شکل شبکه یاد می‌گیرد کدام اطلاعات را فراموش و کدام را حفظ کند.

گیت‌های موجود در ساختار شبکه‌ی حافظه کوتاه مدت ماندگار

• گیت فراموشی ^{۴۹}


این گیت تصمیم می‌گیرد کدام اطلاعات حفظ و کدام فراموش شود. اطلاعات ورودی گام جدید به همراه اطلاعات نهان ^{۵۰} گام قبلی به این گیت وارد می‌شوند و از تابع سیگموئید عبور می‌کنند. خروجی این تابع بین صفر و ۱+ است. هر قدر عدد خروجی به صفر نزدیکتر باشد یعنی باید اطلاعات فراموش شود و هر قدر به ۱+ نزدیکتر باشد یعنی باید حفظ شود.

^{۴۷} cell state

^{۴۸} sigmoid

^{۴۹} Forget Gate

^{۵۰} Hidden State




شکل ۲-۷: گیت فراموشی

• گیت ورودی^{۵۱}

این گیت برای بروزرسانی مقادیر (اطلاعات) موجود در وضعیت سلول تعبیه شده است. اطلاعات ورودی گام جدید به همراه اطلاعات حالت پنهان^{۵۲} گام قبلی، به این گیت وارد می‌شوند و از تابع سیگموئید عبور می‌کنند تا این تابع تصمیم بگیرد کدام اطلاعات دور انداخته و کدام بروزرسانی شوند. همچنین اطلاعات ورودی گام جدید، به همراه اطلاعات حالت پنهان گام قبلی، به تابع تانژانت هایپربولیک وارد می‌شوند تا مقادیرشان میان -1 تا 1 قرار بگیرد. در نهایت خروجی تابع سیگموئید و تابع تانژانت هایپربولیک با هم ضرب می‌شوند تا تابع سیگموئید تصمیم بگیرد چه مقداری از خروجی تابع تانژانت هایپربولیک باید حفظ شوند.

^{۵۱} Input Gate

^{۵۲} hidden state



شکل ۲-۸: گیت ورودی [۵]

• وضعیت سلول^{۵۳}

می‌توانیم با اطلاعات خروجی از گیت فراموشی و ورودی مقادیر وضعیت سلول را آپدیت کنیم. به این شکل که اول مقدار وضعیت سلول در خروجی گیت فراموشی ضرب نقطه‌ای^{۵۴} می‌شود. در این قسمت هر مقداری در وضعیت سلول که با مقدار نزدیک به صفر خروجی گیت فراموشی ضرب شود، فراموش می‌شود و یا اینکه کنار گذاشته می‌شود. بعد از این مرحله مقدار وضعیت سلول با خروجی گیت ورودی جمع نقطه‌ای^{۵۵} می‌شود که مقدار وضعیت سلول با مقادیر جدیدی که شبکه تشخیص داده است لازم هستند به‌روزرسانی شوند. در پایان این مرحله مقادیر وضعیت سلول به‌روزرسانی شده‌اند و جدید هستند.

• گیت خروجی^{۵۶}

این گیت در نهایت تصمیم می‌گیرد که وضعیت پنهان^{۵۷} بعدی چه مقداری باشد. همان طور که میدانیم، وضعیت پنهان اطلاعات ورودی‌های قبلی را همراه خودش دارد. اول اطلاعات ورودی گام جدید به همراه اطلاعات وضعیت پنهان گام قبلی وارد تابع سیگموئید می‌شوند. مقدار آپدیت شده‌ی وضعیت سلول به تابع تانژانت هایپربولیک وارد می‌شود. خروجی این دو تابع با هم ضرب می‌شود تا تصمیم گرفته شود وضعیت پنهان چه اطلاعاتی را با خودش به گام بعدی ببرد. در

^{۵۳} cell state


^{۵۴} pointwise multiplication

^{۵۵} pointwise addition

^{۵۶} output state

^{۵۷} hidden state


نهایت وضعیت سلول جدید و وضعیت پنهان جدید به گام زمانی بعد منتقل می‌شوند [۲۵].



شکل ۲-۹: گیت خروجی [۵]

۲-۳-۴ شبکه عصبی حافظه کوتاه مدت ماندگار دو طرفه ^{۵۸}

در شبکه عصبی بازگشتی یک طرفه، فقط از ورودی‌های قبلی برای پیش‌بینی وضعیت بعدی استفاده می‌شود، در حالی که در شبکه عصبی بازگشتی دو طرفه، از داده‌های آینده هم برای افزایش دقت مدل استفاده می‌شود [۲۶]. در شکل ۲-۱۰ می‌توانید شکل این مدل را مشاهده کنید.



شکل ۲-۱۰: مدل حافظه کوتاه مدت ماندگار دوطرفه [۶]

۵-۳-۲ شبکه عصبی کانولوشنی حافظه کوتاه مدت ماندگار^{۵۹}

مدل کانولوشنی حافظه کوتاه مدت ماندگار شامل یک لایه کانولوشن برای استخراج کردن داده‌های ورودی است.

به دو روش می‌توان این مدل را ایجاد کرد. در روش اول ابتدا مدل کانولوشن را ایجاد می‌کنیم و سپس آن را با قرار دادن کل دنباله لایه‌های کانولوشن در یک لایه TimeDistributed به مدل حافظه کوتاه مدت ماندگار اضافه می‌کنیم.

یک رویکرد جایگزین و شاید خواندن آسان‌تر این است که هر لایه در مدل کانولوشن را در یک لایه TimeDistributed هنگام اضافه کردن آن به مدل اصلی قرار دهیم.

لایه‌های کانولوشنی در یادگیری الگوهای محلی در داده‌ها قدرتمند هستند، در حالی که شبکه حافظه کوتاه مدت ماندگار در یادگیری داده‌های متوالی موثر هستند. ترکیب این دو نوع شبکه می‌تواند منجر به بهبود عملکرد برای کارهای طبقه بندی سری زمانی شود.

به سه روش می‌توان شبکه ی کانولوشنی را با شبکه ی حافظه کوتاه مدت ماندگار ترکیب کرد.

- استفاده کردن از خروجی کانولوشن برای ورودی شبکه‌ی حافظه کوتاه مدت ماندگار. بدین شکل شبکه‌ی حافظه کوتاه مدت ماندگار از ویژگی‌های یادگرفته شده توسط شبکه‌ی کانولوشنی استفاده می‌کند. در این حالت شبکه‌ی کانولوشن الگوهای محلی را در داده‌ها ثبت می‌کند و شبکه‌ی حافظه کوتاه مدت ماندگار می‌تواند وابستگی‌های زمانی را بیاموزد.

- استفاده کردن از خروجی شبکه‌ی حافظه کوتاه مدت ماندگار به عنوان ورودی برای شبکه‌ی کانولوشنی. در این صورت شبکه ی کانولوشنی از ویژگی‌های شبکه‌ی حافظه کوتاه مدت ماندگار استفاده می‌کند. در این حالت شبکه‌ی حافظه کوتاه مدت ماندگار می‌تواند بر یادگیری ویژگی‌های فضایی از خروجی شبکه‌ی حافظه کوتاه مدت ماندگار تمرکز کند.

- استفاده کردن از یک معماری موازی. در این معماری شبکه‌ی حافظه کوتاه مدت ماندگار و کانولوشن به صورت مستقل روی داده‌های ورودی کار می‌کنند و خروجی‌های آنها به یک لایه کاملاً متصل^{۶۰} منتقل می‌شود. خروجی شبکه‌ی کانولوشنی برای استخراج ویژگی‌های فضایی از داده‌های ورودی استفاده می‌شود، در حالی که شبکه‌ی حافظه کوتاه مدت ماندگار برای گرفتن

^{۵۹}CNN-LSTM
^{۶۰}fully connected

وابستگی‌های زمانی بین داده‌های ورودی استفاده می‌شود. سپس خروجی شبکه کانولوشنی و حافظه کوتاه مدت ماندگار با یکدیگر ترکیب شده و به یک لایه کاملاً متصل وارد می‌شوند. این رویکرد ترکیبی اجازه می‌دهد تا از مزایای هر دو مدل استفاده شود [۲۷].

در این فصل مفاهیم پایه و روش‌های تشخیص فعالیت انسانی را بررسی کردیم. ابتدا به توضیح شبکه عصبی، تابع فعالسازی، تابع بهینه سازی و گرادیان کاهشی سپس به بررسی جامع شبکه‌های عصبی عمیق پرداختیم. معایب و انواع شبکه‌های عصبی بازگشتی معرفی شد همچنین مزایای شبکه عصبی کانولوشنی حافظه کوتاه مدت ماندگار نیز گفته شد.

فصل سوم

پیشینه موضوع

در این فصل به مرور الگوریتم‌های یادگیری ماشین پرکاربردی که در حوزه تشخیص فعالیت انسانی مطرح شده است، پرداخته می‌شود.

۳-۱ ماشین بردار پشتیبان^۱

هدف از الگوریتم ماشین بردار پشتیبان، یافتن یک ابر صفحه^۲ در یک فضای n بعدی (تعداد ویژگی‌ها) است که به طور مشخص نقاط داده را طبقه بندی می‌کند.

برای جدا کردن دو دسته از نقاط داده، ابر صفحه‌های ممکن زیادی وجود دارد که می‌توان انتخاب کرد. هدف ما یافتن صفحه‌ای است که بیشترین حاشیه^۳ را داشته باشد، یعنی حداکثر فاصله بین نقاط داده هر دو کلاس.

ابر صفحه‌ها مرزهای تصمیم‌گیری هستند که به طبقه‌بندی نقاط کمک می‌کند [۲۸]. نقاط داده‌ای که هر دو طرف ابر صفحه قرار می‌گیرند را می‌توان به کلاس‌های مختلف نسبت داد. همچنین ابعاد ابر صفحه به تعداد ویژگی‌ها بستگی دارد. اگر تعداد ویژگی‌های ورودی دو باشد، آنگاه ابر صفحه فقط یک خط است. اگر تعداد ویژگی‌های ورودی سه باشد، ابر صفحه به یک صفحه دو بعدی تبدیل می‌شود. نقاط داده با بردارهایی که نزدیکترین نقطه به ابر صفحه هستند و بر موقعیت ابر صفحه تاثیر می‌گذارند، بردار پشتیبان نامیده می‌شوند. از آنجایی که این بردارها ابر صفحه را پشتیبانی می‌کنند، بنابراین بردار پشتیبان نامیده می‌شوند [۲۸].

مطالعه دیگری که توسط ترن^۴ و همکاران ارائه شده است. برای شناخت شش عمل اصلی که مبتنی بر راه رفتن است، ایستاده، نشسته، دراز کشیده، بالا و پایین. این فعالیت‌ها توسط حسگرهای تلفن همراه ضبط شده است. مجموعه‌ای از ویژگی‌هایی مانند تفاوت در داده‌های حسگرها، بزرگی، تبدیل فوریه سریع، طول پنجره، میانگین، انحراف معیار، حداکثر، حداقل، انرژی و آنتروپی. طبقه بندی کننده ماشین بردار پشتیبان استفاده شد و کیفیت ویژگی‌ها و کیفیت آموزش مدل به افزایش عملکرد کمک می‌کند. تعداد ویژگی‌های به دست آمده از این مدل ۲۴۸ است. دقت به دست آمده از سیستم پیشنهادی ۸۹.۵۹ درصد بود [۲۹].

^۱ Support Vector Machine

^۲ Hyperplane

^۳ Margine

^۴ Tran

۲-۳ درخت تصمیم‌گیری^۵

یک ابزار برای پشتیبانی از تصمیم است که از درخت‌ها برای مدل کردن استفاده می‌کند. درخت تصمیم به‌طور معمول در تحقیق‌ها و عملیات مختلف استفاده می‌شود. به‌طور خاص در آنالیز تصمیم، برای مشخص کردن استراتژی که با بیشترین احتمال به هدف برسد، بکار می‌رود.

خان و همکاران روش یادگیری ماشین با استفاده از طبقه‌بندی درخت تصمیم داده‌ها بر اساس Wii به دست آمده یا گرفته شده است ریموت که وسیله‌ای آماده، سبک، کوچک و آسان برای تشخیص فیزیکی اولیه محسوب می‌شود فعالیت‌ها.

یک مطالعه پیشنهاد شده توسط kwapisze و همکاران، از یک سیستم دست ساز استفاده کرد برای بدست آوردن ویژگی‌ها از داده‌های حسگر آنها انواع مختلفی از روش‌های یادگیری ماشین را برای طبقه‌بندی به کار بردند.

چندین طبقه‌بندی‌کننده مانند J48، رگرسیون لجستیک، پرسپترون چند لایه و Strawman استفاده شد. دقت‌های حاصل از J48، رگرسیون لجستیک، شبکه چند لایه ۸۵.۱، ۷۸.۱، ۹۱.۷ و ۳۷.۲ است. به ترتیب. درخت‌های تصمیم شبکه چند لایه و J48 بالاترین عملکرد را از نظر دقت در مقایسه با آن نشان داده‌اند سایر روش‌های یادگیری ماشینی حداکثر دقت بدست آمده توسط شبکه چند لایه با مقدار ۹۱.۷ بود [۳۰].

۳-۳ یادگیری انتقالی^۶

یک موضوع تحقیقاتی در یادگیری ماشین است که بر روی ذخیره دانش به دست آمده در هنگام حل یک مسئله و استفاده از آن در یک مسئله متفاوت ولی مرتبط متمرکز است. به عنوان مثال، دانش به دست آمده در هنگام یادگیری شناخت ماشین می‌تواند هنگام تلاش برای شناسایی کامیون‌ها به کار رود. از دیدگاه عملی، استفاده دوباره یا انتقال اطلاعات از وظایف قبلاً یاد گرفته شده برای یادگیری وظایف جدید این توانایی را دارد که به‌طور قابل توجهی کارایی نمونه یک عامل یادگیری تقویت‌کننده را بهبود بخشد [۳۱].

ایده‌ی کلی یادگیری انتقالی این است که از دانشی که مدل برای حل یک وظیفه با حجم زیادی داده به

^۵ Decision Tree


^۶ Transfer learning

دست آورده است برای وظیفه‌ی دیگری که این حجم داده را در دسترس ندارد استفاده کنیم؛ به جای این هم که یادگیری شبکه از صفر شروع شود، با الگوهای یادگرفته‌شده شروع می‌کنیم که در حین حل کردن وظیفه‌ای دیگر به دست آمده است.

پاولیوک و همکارانش یک مدل یادگیری عمیق پیشنهاد دادند. این مدل از قبل روی بر روی اسکالوگرام‌های تولید شده توسط CWT(Continuous wavelet transform) آموزش داده شده است. و در نتیجه روی داده‌های KU-HAR صحت ۹۷.۴۸ درصد را دارد.

۴-۳ H-SVM

برای این پروژه از یک برنامه جمع‌آوری داده بر روی ساعت هوش مصنوعی Samsung GEAR استفاده شده است. داده‌های خام حسگر شتاب‌سنج با فرکانس نمونه‌برداری ۵۰ هرتز جمع‌آوری شده است. فعالیت‌ها شامل چهار نوع حرکت: نشستن، ایستادن، راه رفتن و دویدن است. فرکانس نمونه‌برداری اصلی ۵۰ هرتز بود، اما در این آزمایش‌ها به چهار نوع فرکانس نمونه‌برداری تقسیم کردیم: ۵۰ هرتز، ۲۵ هرتز، ۱۰ هرتز و ۵ هرتز. در این آزمایش‌ها ما پنج داوطلب شرکت کردند. تمامی داوطلبان مرد و سن آن‌ها بین ۲۴ تا ۲۵ سال بود. داوطلبان با شماره‌های A, B, C, D و E شناسایی شده‌اند. هر حرکت هر شخص به مدت ۴ دقیقه (۲۴۰ ثانیه) نمونه‌برداری شد. به منظور جلوگیری از تأثیر داده‌های جانبی، ۲۰ ثانیه اول و ۲۰ ثانیه آخر هر مجموعه داده حذف شدند. بنابراین هر مجموعه داده ۲۰۰ ثانیه بود.



شکل ۳-۱: مدل svm [۶]

روش‌های انتخاب ویژگی، ویژگی‌هایی را انتخاب می‌کنند که بیشترین تمیزدهی را دارند و بیشترین مشارکت را در عملکرد طبقه‌بندی دارند تا یک زیرمجموعه از ویژگی‌های موجود ایجاد شود. اگرچه ماشین‌های بردار پشتیبانی ماشین بردار روش‌های محاسبات عصبی قدرتمندی هستند، عملکرد آن‌ها به دلیل وجود تعداد زیادی ویژگی بی‌ارتباط کاهش می‌یابد. بنابراین، روش‌های انتخاب ویژگی H-SVM

پیشنهاد شده‌اند.

ویژگی‌های انتخاب شده یا کاهش یافته که مجموعه‌های ویژگی ایجاد می‌کنند به عنوان ورودی‌ها برای روش‌های طبقه‌بندی و تشخیص استفاده می‌شوند. در زیر خلاصه‌ای از معتبرترین روش‌های طبقه‌بندی و تشخیص آمده است [۳۲].

- J48: J48 ابزارهای پشتیبانی تصمیم‌گیری هستند که از مدل درختی تصمیم‌گیری و پیامدها و هزینه‌های آن استفاده می‌کنند.

- **جداول تصمیم‌گیری^۷**: جداول تصمیم‌گیری به عنوان یک ساختار کاربرد دارند که برای توصیف مجموعه‌ای از قوانین تصمیم‌گیری و ثبت الگوهای تصمیم‌گیری برای اتخاذ تصمیمات سازگار مورد استفاده قرار می‌گیرند.

- **نیو بیز^۸**: نیو بیز یک طبقه‌بند احتمالاتی ساده بر اساس قضیه بیز است.

- **ماشین بردار پشتیبان**: ماشین بردار پشتیبان روش‌های یادگیری نظارتی هستند که برای طبقه‌بندی استفاده می‌شوند. ما مقادیر مشخصه‌ای انتخاب شده را به طبقه‌بندهای مختلفی قرار دادیم.

در شکل ۳-۱ دقت‌های طبقه‌بندی‌های مختلف را می‌توانید مشاهده کنید.

	% of Records Correctly Predicted			
	50Hz	25Hz	10Hz	5Hz
Sitting	99.31	99.86	99.99	99.87
Standing	98.49	99.02	98.95	98.62
Walking	98.99	99.78	99.91	99.67
Running	99.34	99.90	99.64	99.85
Overall	99.03	99.64	99.62	99.50

شکل ۳-۲: دقت مدل H-SVM [۶]

DT^۷
NB^۸

۳-۵ جنگل تصادفی^۹

یک روش نظارت شده است که در زمان آموزش تعداد زیادی از درخت‌های تصمیم به صورت مستقل به عنوان یک انجمن ایجاد می‌کند، و خروجی آن، طبقه‌بندی هر درخت فردی است. این روش عملکرد طبقه‌بندی را با استفاده از "فیچر بگینگ" بهبود می‌بخشد، که این به تغییر الگوریتم درخت تصمیم به منظور انتخاب یک زیرمجموعه تصادفی از ویژگی‌ها می‌پردازد. هر درخت فردی پیش‌بینی کلاسی دارد و کلاسی که بیشترین آراء را دارد، پیش‌بینی مدل خواهد شد. جنگل تصادفی یک روش موثر برای رتبه‌بندی اهمیت متغیرها در یک مسئله طبقه‌بندی است. برخلاف سایر طبقه‌بندی‌های درخت تصمیم، هر درخت در جنگل تصادفی تنها می‌تواند یک زیرمجموعه تصادفی از ویژگی‌ها را انتخاب کند که این امر افزایش تنوع میان درخت‌ها در مدل را ممکن می‌سازد. بنابراین، طبقه‌بندی با توجه به کمبود همبستگی بین درخت‌ها، به دقت بالاتری ختم می‌شود. اگرچه جنگل تصادفی ممکن است در طبقه‌بندی دقت بهتری داشته باشد، تعداد زیادی از درخت‌ها ممکن است الگوریتم را برای پیش‌بینی به صورت زمان واقعی کند و غیرموثر کند.

یک روش یادگیری ترکیبی برای دسته‌بندی، رگرسیون می‌باشد، که بر اساس ساختاری متشکل از شمار بسیاری درخت تصمیم، بر روی زمان آموزش و خروجی کلاس‌ها یا برای پیش‌بینی‌های هر درخت به شکل مجزا، کار می‌کنند. جنگل‌های تصادفی برای درختان تصمیم که در مجموعه‌ی آموزشی دچار بیش‌برازش می‌شوند، مناسب هستند. عملکرد جنگل تصادفی معمولاً بهتر از درخت تصمیم است، اما این بهبود عملکرد تا حدی به نوع داده هم بستگی دارد [۳۳].

پرابات کومار و همکارانش از یک مدل جنگل تصادفی برای مجموعه داده‌ی FLAPP که ۱۰ نوع فعالیت دارد استفاده کردند و در نهایت به دقت ۷۷.۲۲ درصد رسیدند [۳۴].

در این فصل به بررسی پنج متد تشخیص فعالیت انسانی با استفاده از متدهای یادگیری ماشین و یادگیری عمیق پرداختیم. هر کدام از این روش‌ها را توضیح دادیم و میزان دقت آنها را مقایسه کردیم. مدل H-SVM از بین مدل‌های دیگر بالاترین دقت را داشت.

فصل چهارم

ابزارهای پیاده‌سازی

۴-۱ ابزارها و کتابخانه‌های مورد استفاده

در این بخش به بررسی ابزارهای مورد استفاده در این بخش می‌پردازیم.

۴-۱-۱ تنسورفلو^۱

تنسورفلو یک کتابخانه نرم‌افزاری رایگان و متن باز برای یادگیری ماشین و هوش مصنوعی است و می‌توان از آن در طیف وسیعی از وظایف استفاده کرد، اما تمرکز ویژه‌ای بر آموزش و استنتاج شبکه‌های عصبی عمیق دارد. تنسورفلو کاربران را قادر می‌سازد تا نمودارها و ساختارهای جریان داده بسازند تا با در نظر گرفتن ورودی‌ها به عنوان یک آرایه چند بعدی به نام تنسور نحوه حرکت داده‌ها را تعریف کنند. تنسورفلو ورودی را به عنوان یک آرایه چند بعدی می‌گیرد، سپس از طریق سیستم عملیاتی جریان می‌یابد و از انتهای دیگر به عنوان خروجی خارج می‌شود [۳۵].

۴-۱-۲ نامپای^۲

نامپای یک کتابخانه اساسی برای محاسبات علمی در پایتون است که استفاده از آرایه را در پایتون فراهم می‌کند. برخلاف فهرست‌های پایتون که می‌توانند به صورت پویا رشد کنند آرایه‌های نامپای اندازه ثابتی در هنگام ایجاد دارند و باید همه از یک نوع داده باشند. آرایه‌های نامپای عملیات ریاضی و سایر عملیات پیشرفته را بر روی تعداد زیادی داده تسهیل می‌کنند و به طور معمول این عملیات را با کد کمتر و کارآمدتر نسبت به آنچه ممکن است با استفاده از دنباله‌های داخلی پایتون اجرا می‌شوند [۳۶].

۴-۱-۳ کراس^۳

کراس یک کتابخانه متن باز است که یک رابط پایتون برای شبکه‌های عصبی مصنوعی ارائه می‌کند. کراس به عنوان یک رابط برای کتابخانه تنسورفلو عمل می‌کند. کراس شامل پیاده‌سازی‌های متعددی از بلوک‌ها رایج شبکه عصبی مانند لایه‌ها، توابع فعال‌سازی، بهینه‌سازها و مجموعه‌ای از ابزارها برای آسان‌تر کردن کار با داده‌های تصویر و متن و برای ساده‌سازی کدگذاری لازم برای نوشتن کد شبکه عصبی

^۱Tensorflow

^۲numpy

^۳Keras

عمیق است. کراس علاوه بر شبکه‌های عصبی استاندارد، از شبکه‌های عصبی کانولوشنی و بازگشتی نیز پشتیبانی می‌کند [۳۷].

۴-۱-۴ پانداس^۴

پانداس یک کتابخانه متن‌باز با کارایی بالا است که ساختاری را با قابلیت استفاده آسان و ابزارهای تحلیل داده برای زبان برنامه‌نویسی پایتون فراهم می‌کند. در واقع می‌توان گفت پانداس یک کتابخانه قدرتمند برای تحلیل، پیش‌پردازش و بصری‌سازی داده‌ها است [۳۸].

۴-۱-۵ متپلات لیب^۵

متپلات لیب یک کتابخانه برای تجسم داده و رسم گرافیکی برای زبان پایتون است. یک اسکریپت متپلات لیب به گونه‌ای ساختار یافته است که چند خط کد تنها چیزی است که در بیشتر موارد برای تولید نمودار داده بصری لازم است. بدین ترتیب یک جایگزین منبع باز مناسب برای متلب ارائه می‌دهد [۳۹].

۴-۱-۶ سایکیت لرن^۶

کتابخانه سایکیت لرن یک کتابخانه یادگیری ماشین رایگان برای زبان برنامه‌نویسی پایتون است که دارای الگوریتم‌های مختلف طبقه‌بندی، رگرسیون، خوشه‌بندی، جنگل تصادفی و غیره است. این کتابخانه برای تعامل با کتابخانه‌های عددی پایتون نظیر نامپای طراحی شده است [۴۰].

در این بخش ابزارها و کتابخانه‌های مورد استفاده در این پروژه بررسی شد و هر کدام از کتابخانه‌های استفاده شده توضیح داده شد.

^۴pandas
^۵matplotlib
^۶Scikit-learn

فصل پنجم

پیاده سازی مدل ها و پیش پردازش داده ها

تمام کدهای این قسمت در این **لینک گیتهاب**^۱ موجود است.

۵-۱ معرفی مجموعه دادگان و پیش پردازش آن


در این قسمت به بررسی مجموعه دادگان و مراحل پیش پردازش داده می پردازیم.

۵-۱-۱ معرفی مجموعه دادگان

مجموعه داده ی مورد استفاده در این پروژه دیتاست UCI است. در این دیتاست داده هایژیروسکوپ و شتاب سنج ۳۰ شرکت کننده ثبت شده است. این داده ها توسط تلفن های هوشمندی که در جیب افراد قرار داشته بدست آمده است. شش نوع فعالیت ثبت شده که هر کدام از این فعالیت ها به مدت ۶۰ ثانیه انجام شده است. فعالیت های ثبت شده شامل : نشستن ، ایستادن ، دراز کشیدن ، راه رفتن، از پله بالا رفتن و از پله پایین آمدن است.

سه نوع سیگنال اصلی در داده های خام وجود دارد: شتاب کل، شتاب بدنه وژیروسکوپ بدنه. هر کدام از این سه سیگنال دارای سه محور هستند. پس به صورت کلی برای هر گام زمانی ما ۹ متغیر داریم. علاوه بر آن هر سری داده به پنجره های ۲.۵۶ ثانیه ای از داده ها تقسیم شده است.

پس هر سطر از داده ها شامل $(128 * 9)$ یا ۱۱۵۲ پارامتر است.




شکل ۵-۱: سیگنال خام شتاب سنج


^۱https://github.com/Tahoora78/Human_Activity_Recognition




شکل ۵-۲: سیگنال خام ژيروسکوپ




شکل ۵-۳: سیگنال مربوط به راه رفتن




شکل ۴-۵: سیگنال مربوط به از پله بالا رفتن




شکل ۵-۵: سیگنال مربوط به از پله پایین آمدن



شکل ۵-۶: سیگنال مربوط به نشستن



شکل ۵-۷: سیگنال مربوط به ایستادن



شکل ۵-۸: سیگنال مربوط به دراز کشیدن

۵-۱-۲ تحلیل مجموعه دادگان

برای بدست آوردن فیچر های های مناسب از این دیتاست نیازمند دانش تخصصی بودیم اما با استفاده از یک لایه کانولوشنی می توان این ویژگی ها را از دیتاست استخراج کرد. با کانوالو کردن داده ی ورودی با هسته درست می توان این ویژگی ها را بدست آورد. در واقع می توان با استفاده از هسته ها الگوهای متفاوت داده ها را بدست آورد.

۵-۱-۳ پیش پردازش داده ها

برای از بین بردن نویز داده ها از فیلتر میانه و فیلتر پایین گذر باترورث استفاده شده است. فیلتر میانه با طول ۵ روی داده های ژيروسکوپ و شتاب سنج اعمال شده و می توانید در شکل تفاوت آن را با حالت اولیه مشاهده کنید. بعد از انجام مراحل پیش پردازش داده ها، آنها را به پنجره هایی با اندازه ی ثابت ۵۶.۲ ثانیه یا همان ۱۲۸ داده تقسیم میکنیم. سپس داده های شتاب سنج را به داده های گرانشی ^۲ و حرکتی تقسیم میکنیم.

نرمالایز کردن داده ها ^۳

برای نرمالایز کردن داده ها از میانگین و انحراف معیار استفاده می کنیم. بدین شکل که داریم:

$$\text{signal} = (\text{signal} - \text{mean}) / \text{std}$$

میانگین سیگنال با mean و انحراف معیار سیگنال با std نمایش داده شده است.

قسمت بندی کردن داده ها ^۴

سیگنال های سنسورها را به پنجره هایی با طول ثابت تقسیم می کنیم. به این شکل که هر کدام از پنجره ها ۲.۵۶ ثانیه و با هم پوشانی ^۵ ۵۰٪ که حدودا همان ۱۲۸ سطر می شود. به این دلیل این تقسیم بندی را به این شکل انجام می دهیم چون میانگین زمان انجام هر فعالیت حدود ۲.۵۶ ثانیه است.

^۲gravitational

^۳Normalizing

^۴Data segmentation


^۵overlap

فیلترهای اعمال شده روی دیتاست برای پیش پردازش داده ها

• فیلتر میانه

فیلتر میانه یکی از فیلترهای غیرخطی در فیلتر دیجیتال است. از این فیلتر برای گرفتن نویز پالسی استفاده می شود. الگوریتم کلی فیلتر میانه با پیدا کردن میانه و جایگزینی آن در مجموعه ورودی کار می کند (میانه یک بردار عنصر میانی برای یک بردار فرد عضو یا میانگین دو عنصر میانی برای یک بردار زوج عضو تعریف می شود) به عنوان مثال اگر وروی یک بردار با طول K و فرد باشد فیلتر عنصر میانی را به عنوان میانه آن بردار اعلام می کند. در حالتی که ورودی یک بردار یا فضای یک بعدی باشد باید به جای هر K عنصر متوالی میانه آن را جایگزین کنیم [۴۱].

median filter



شکل ۵-۹: سیگنال شتاب بعد از فیلتر میانه




شکل ۵-۱۰: سیگنال ژيروسکوپ بعد از فیلتر میانه

• فیلتر باترورث^۷

فیلتر باترورث نوعی فیلتر پردازش سیگنال است که به گونه ای طراحی شده است که فیلتر باترورث نوعی فیلتر الکترونیکی است که برای حذف فرکانس های ناخواسته از سیگنال ها یا افزایش فرکانس های خاص استفاده می شود. این نوع فیلتر دارای طراحی منحصر به فردی است که پاسخ فرکانسی را در باند عبور^۸ تا حد امکان یکنواخت^۹ داشته باشد [۴۲].

در فیلتر باترورث یک شماره ترتیب^{۱۰} برای فیلتر باترورث وجود دارد. این شماره ترتیب به شرایط یکنواخت پاسخ فرکانس اشاره می کند. مقادیر کوچک تر شماره ترتیب باعث ایجاد شرایط یکنواخت پاسخ فرکانس کمتر می شود. در غیر این صورت، مقدار بزرگ تر شماره ترتیب باعث ایجاد شرایط یکنواخت فرکانس تیزتر/صاف تر می شود.

Butterworth filter^۷
passband^۸
flat^۹
order number^{۱۰}



شکل ۵-۱۱: سیگنال شتاب بعد از فیلتر میانه و باترورث



شکل ۵-۱۲: سیگنال ژيروسکوپ بعد از فیلتر میانه و باترورث

۲-۵ ارزیابی مدل های شبکه عصبی مصنوعی

روش های مختلفی برای ارزیابی الگوریتم های دسته بندی وجود دارد که می توان به صحت^{۱۱}، دقت^{۱۲}، پوشش^{۱۳} و نمره F1^{۱۴} اشاره کرد. نحوه محاسبه معیارهای ارزیابی به شکل زیر انجام می شود:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (۱-۵)$$

$$Precision = \frac{TP}{TP + FP} \quad (۲-۵)$$

$$Recall = \frac{TP}{TP + FN} \quad (۳-۵)$$

$$F1 = \frac{2 * Precision * Recall}{Precision + Recall} \quad (۴-۵)$$

در این رابطه:

TP: مثبت صحیح (مدل بدرستی جواب مثبت را پیش بینی کرده است)

FP: مثبت غلط (مدل جواب را به اشتباه مثبت پیش بینی کرده است)

FN: منفی غلط (مدل به اشتباه جواب را منفی پیش بینی کرده است)

TN: منفی صحیح (مدل بدرستی جواب را مثبت پیش بینی کرده است)

۱-۲-۵ شبکه عصبی کانولوشنی

در این قسمت به بررسی پیاده سازی های انجام شده برای شبکه عصبی کانولوشنی می پردازیم. معماری کلی برای شبکه عصبی کانولوشنی برای تشخیص فعالیت انسان دارای ۱۶۷۹ پارامتر است. لایه ی اول ورودی این شبکه دارای سایز (۱۲۸ و ۶) است سپس یک لایه کانولوشن یک بعدی با اندازه ی فیلتر ۳۲ و اندازه ی هسته ۳ داریم. بعد از آن یک لایه حذف تصادفی با احتمال ۰.۳ برای جلوگیری از بیش برازش استفاده شده است. و بعد یک لایه maxPooling و لایه dense داریم.


^{۱۱}Accuracy

^{۱۲}Accuracy


^{۱۳}Recall

^{۱۴}F1-score

تابع فعال سازی استفاده شده در این لایه ^{۱۵} و همچنین برای جلوگیری از بیش برآزش از پارامتر kernel-regularizer از نوع 12 با مقدار ۰.۰۰۱ استفاده شده است. روی لایه ی آخر تابع فعال سازی بیشینه هموارساز استفاده شده است. معماری کلی شبکه در شکل زیر نشان داده شده است.




شکل ۵-۱۳: معماری شبکه عصبی کانولوشنی به شکل کلی



شکل ۵-۱۴: معماری شبکه عصبی کانولوشنی

سپس مدل با تابع خطای categorical-crossentropy و همچنین نرخ آموزش ۰.۰۰۱ کامپایل می شود. مدل روی داده های آموزش با ۱۰۰۰ اپیاک آموزش می بیند. همچنین ۰.۲ از داده ها در حین آموزش به عنوان داده اعتبارسنجی در نظر گرفته می شوند.

پس از آموزش نمودارهای خطا و صحت را برحسب اپیاک رسم می کنیم. در شکل زیر نمودارهای خطا و صحت بر حسب اپیاک در داده های آموزشی و اعتبارسنجی برای مدل شبکه عصبی کانولوشنی نوع اول را نشان می دهد. نمودار خطا دارای سیر نزولی و نمودار صحت دارای سیر صعودی است.




شکل ۵-۱۵: نمودار خطا و صحت برای شبکه عصبی کانولوشنی

پس از آموزش مدل را روی داده های تست آزمایش می کنیم و به صحت ۹۳ درصد می رسیم. چون از k fold cross validation استفاده کردیم معیار های دقت را به صورت میانگین ثبت میکنیم. معیارهای ارزیابی در شکل زیر نمایش داده شده است.

```
---Final Test Scores Averaged over Folds---
accuracy=0.9331774139659205
precision=0.9332762801879464
recall=0.9345405537198245
f1=0.9329345573554675
```

شکل ۵-۱۶: نتایج آزمایش داده های تست بر روی شبکه عصبی کانولوشن

همچنین نمودار ماتریس درهم ریختگی نیز در تصویر زیر برای سه داده ی تست ، آموزشی و اعتبار سنجی رسم شده است.




شکل ۵-۱۷: ماتریس درهم ریختگی برای شبکه عصبی کانولوشنی


۵-۲-۲ شبکه عصبی عمیق کانولوشنی حافظه کوتاه مدت ماندگار^{۱۶}

معماری این شبکه بدین شکل است که در ابتدا سه لایه کانولوشن یک بعدی با اندازه ی ۳۲ داریم. از لایه کانولوشنی یک بعدی برای استخراج ویژگی ها از داده ها استفاده می کنیم. سپس سه لایه حافظه کوتاه مدت ماندگار شبکه حافظه کوتاه مدت ماندگار داریم. برای جلوگیری از بیش برآزش مدل از دو لایه حذف تصادفی با مقدار ۰.۵ استفاده شده است. برای جلوگیری از بیش برآزش از پارامتر kernel-regularizer از نوع 12 با مقدار ۰.۰۱ استفاده شده است.

معماری کلی شبکه در شکل ۵-۱۲ نمایش داده شده است.




شکل ۵-۱۸: نمودار کلی شبکه کانولوشنی حافظه کوتاه مدت ماندگار



شکل ۵-۱۹: نمودار شبکه کانولوشنی حافظه کوتاه مدت ماندگار

برای کامپایل و آموزش همان مراحل قبلی را طی می کنیم. پس از آموزش نمودارهای خطا و صحت را بر حسب ایپاک رسم می کنیم. شکل ۵-۱۴ نمودارهای خطا و صحت بر حسب ایپاک در داده های آموزشی و اعتبارسنجی برای مدل شبکه عصبی کانولوشنی حافظه طولانی کوتاه مدت را نمایش می دهد. همانطور که مشاهده می شود نمودار خطا دارای سیر نزولی و نمودار صحت دارای سیر صعودی است. در ایپاک های آخر نمودارهای آموزش و اعتبارسنجی همگرا می شوند.




شکل ۵-۲۰: نمودار خطا و صحت برای شبکه عصبی کانولوشنی حافظه طولانی کوتاه مدت

بعد از آموزش مدل را روی داده های تست آزمایش می کنیم و به صحت ۹۴.۳ درصد می رسیم. برای حالت میانگین مدل دارای دقت ۹۴.۴، پوشش ۰.۹۴۵ درصد و نمره f1 ۹۴.۳ درصد است. مقادیر گفته شده به صورت کامل در شکل ۵-۱۵ قابل مشاهده است.

```
---Final Test Scores Averaged over Folds---
accuracy=0.9438690277313732
precision=0.94446600928477
recall=0.9454895922519923
f1=0.9436354646961974
per-class f1=[0.9981685  0.94267516 0.97314715 0.92596685 0.90480864 0.91704649]
```

شکل ۵-۲۱: نتایج آزمایش داده های تست بر روی شبکه عصبی کانولوشنی حافظه کوتاه مدت ماندگار

همچنین در شکل ۵-۱۸ می توانید ماتریس درهم ریختگی این مدل را مشاهده کنید.



شکل ۵-۲۲: ماتریس درهم ریختگی شبکه عصبی کانولوشنی حافظه کوتاه مدت ماندگار


۳-۲-۵ شبکه عصبی حافظه طولانی کوتاه مدت

در این قسمت به بررسی پیاده سازی های انجام شده برای شبکه عصبی حافظه طولانی کوتاه مدت می پردازیم. معماری کلی این شبکه ها بدین شکل است که ابتدا یک لایه شبکه حافظه کوتاه مدت ماندگار با اندازه ورودی (۱۲۸ و ۶) داریم. سپس می توانیم یک یا چند لایه شبکه حافظه کوتاه مدت ماندگار و لایه flatten و یا لایه متراکم داشته باشیم.


۴-۲-۵ شبکه عصبی حافظه طولانی کوتاه مدت نوع اول

معماری این شبکه بدین شکل است که در ابتدا یک لایه شبکه حافظه کوتاه مدت ماندگار با اندازه ۳۲ و ورودی (۱۲۸ و ۶) داریم. سپس برای جلوگیری از بیش برآزش داده ها یک لایه ی حذف تصادفی با اندازه ی ۰.۵ قرار دارد. بعد از آن یک لایه ی کاملاً متصل به هم با اندازه ی ۳۲ قرار داده شده است. در نهایت یک لایه ی کاملاً متصل به هم با اندازه ی ۶ که تعداد فعالیت هایی است که مدل باید تشخیص دهد قرار دارد. روی این لایه آخر تابع فعال سازی بیشینه هموار ساز استفاده شده است. معماری کلی شبکه در شکل ۵-۱۷ نشان داده شده است. مدل با تابع هزینه آنتروپی متقاطع^{۱۷} و تابع بهینه سازی آدام با مقدار ۰.۰۰۱ کامپایل شده است. تعداد پارامترهای این شبکه برابر ۶۲۴۶ است.

^{۱۷}categorical-crossentropy




شکل ۵-۲۳: معماری کلی شبکه حافظه کوتاه مدت طولانی



شکل ۵-۲۴: معماری شبکه حافظه کوتاه مدت طولانی

پس از آموزش نمودارهای خطا و صحت را بر حسب ایپاک رسم می کنیم. شکل ۵-۱۸ نمودارهای خطا و صحت بر حسب ایپاک در داده های آموزشی و اعتبارسنجی برای مدل شبکه عصبی حافظه طولانی کوتاه مدت نوع اول را نشان می دهد. همان طور که مشاهده می شود نمودار خطا دارای سیر نزولی و نمودار صحت دارای سیر صعودی است و در ایپاک های آخر نمودارهای داده های آموزش و اعتبارسنجی همگرا می شوند. صحت روی داده های آموزش از ۶۲ درصد شروع و به ۹۵ درصد می رسد و برای داده های اعتبارسنجی صحت از ۰.۶۰ درصد شروع شده و به ۹۵.۶ درصد می رسد. همچنین تابع خطا نیز برای داده های آموزش از ۱۰۶ درصد شروع شده و به ۱۱ درصد کاهش پیدا می کند. برای داده های اعتبارسنجی نیز تابع خطا ۱۰۳ درصد شروع شده و به ۱۲ درصد کاهش پیدا می کند.




شکل ۵-۲۵: نمودار خطا و صحت برای شبکه حافظه طولانی کوتاه مدت نوع اول

بعد از آموزش مدل را روی داده های تست آزمایش می کنیم و به صحت ۹۴.۸ درصد می رسیم. برای حالت میانگین مدل دارای دقت ۹۴.۹ درصد، پوشش ۹۵ درصد و نمره f1 ۹۴.۹ درصد است. مقادیر گفته شده به صورت کامل در شکل ۵-۲۰ قابل مشاهده است.

```
---Final Test Scores Averaged over Folds---
accuracy=0.9375208820581357
precision=0.9384635226408576
recall=0.9391373100113056
f1=0.9382964724941535
per-class f1=[0.99634369 0.94780793 0.9527897 0.95852535 0.87367406 0.9006381 ]
```

شکل ۵-۲۶: نتایج آزمایش داده های تست بر روی شبکه حافظه طولانی کوتاه مدت نوع اول

همچنین در شکل ۵-۲۱ می توانید ماتریس درهم ریختگی این مدل را مشاهده کنید.




شکل ۵-۲۷: ماتریس درهم ریختگی برای شبکه عصبی حافظه طولانی کوتاه مدت نوع اول

۵-۲-۵ شبکه عصبی حافظه طولانی کوتاه مدت دوطرفه^{۱۸} در معماری نوع اول

در این قسمت همان معماری شبکه عصبی حافظه طولانی کوتاه مدت نوع اول را نگه داشته اما به جای استفاده از شبکه حافظه کوتاه مدت ماندگار ساده از شبکه حافظه کوتاه مدت ماندگار دوطرفه استفاده می کنیم. مراحل کامپایل و آموزش همانند مراحل قبل است.

پس از آموزش نمودارهای خطا و صحت را بر حسب ایپاک رسم می کنیم. شکل ۵-۲۲ نمودارهای خطا و صحت بر حسب ایپاک در داده های آموزشی و اعتبارسنجی برای مدل شبکه عصبی حافظه طولانی کوتاه مدت دوطرفه نوع اول را نشان می دهد. همانطور که مشاهده می شود نمودار خطا دارای سیر نزولی و نمودار صحت دارای سیر صعودی است. صحت روی داده های آموزشی از ۶۰ درصد شروع شده و به ۹۵ درصد می رسد و برای داده های اعتبارسنجی از ۶۲ درصد شروع شده و به ۹۴.۹ درصد می رسد. همچنین تابع خطا نیز برای داده های آموزش از ۱۰۶ درصد شروع شده و به ۱ درصد کاهش پیدا می کند. برای داده های اعتبارسنجی نیز تابع خطا از ۱۰۳ درصد شروع شده و به ۱۸ درصد کاهش پیدا می کند.




شکل ۵-۲۸: نمودار خط و صحت برای شبکه حافظه طولانی کوتاه مدت دو طرفه نوع اول

بعد از آموزش مدل را روی داده های تست آزمایش می کنیم و به صحت ۹۴.۵ درصد می رسیم. برای حالت میانگین دقت ۹۴.۳ درصد ، پوشش ۹۴.۴ درصد و نمره f1 ۹۴.۱ درصد است. مقادیر گفته شده به صورت کامل در شکل ۵-۲۳ قابل مشاهده است. در مقایسه با حالتی که از شبکه عصبی حافظه کوتاه مدت ساده استفاده می کردیم می توان گفت که صحت ، دقت ، پوشش و نمره f1 بهبود یافته است. صحت از مقدار ۹۳ درصد به ۹۴.۵ درصد و پوشش از مقدار ۹۳ درصد به مقدار ۹۴.۴ درصد بهبود یافته است.

```
---Final Test Scores Averaged over Folds---
accuracy=0.9425325760106916
precision=0.9432722660162227
recall=0.9442455141692935
f1=0.9427888835165011
per-class f1=[0.99000908 0.95208333 0.9650655 0.94051627 0.90097087 0.90808824]
```

شکل ۵-۲۹: نتایج آزمایش داده های تست بر روی شبکه حافظه طولانی کوتاه مدت دوطرفه نوع اول

همچنین در شکل ۵-۲۴ می توانید ماتریس در هم ریختگی مربوط به سه نوع داده ی تست و آموزش و ارزیابی را مشاهده کنید.




شکل ۵-۳: ماتریس درهم ریختگی شبکه حافظه طولانی کوتاه مدت دوطرفه نوع اول

۵-۲-۶ شبکه عصبی حافظه کوتاه مدت ماندگار پشته ای


معماری این شبکه به این صورت است که در ابتدا یک لایه ی شبکه حافظه کوتاه مدت ماندگار داریم سپس برای جلوگیری از بیش برآزش مدل یک لایه حذف تصادفی با مقدار ۰.۳ داریم. سپس دو لایه شبکه حافظه کوتاه مدت ماندگار با مقدار ۲۵ و ۱۶ قرار دارد. و در آخر یک لایه حذف تصادفی و یک لایه dense داریم.

برای جلوگیری از بیش برآزش از پارامتر kernel-regularizer از نوع L2 با مقدار ۰.۰۱ استفاده شده است.

در نهایت نیز یک لایه کاملاً متصل با اندازه ۶ که به اندازه کلاس های فعالیت ها است قرار داده شده است و در نهایت روی این لایه آخر تابع فعال سازی بیشینه هموار ساز استفاده شده است. این مدل دارای ۱۰۲۴۴ پارامتر قابل یادگیری است. معماری کلی شبکه در شکل زیر نمایش داده شده است.




شکل ۵-۳۱: معماری کلی شبکه حافظه کوتاه مدت ماندگار پشته ای



شکل ۵-۳۲: معماری شبکه حافظه کوتاه مدت ماندگار پشته ای

برای کامپایل و آموزش همان مراحل قبلی را طی می کنیم. سپس نمودارهای خطا و صحت را بر حسب ایپاک رسم می کنیم. در شکل ۵-۲۷ نمودارهای خطا و صحت بر حسب ایپاک در داده های آموزشی

و اعتبارسنجی برای مدل شبکه حافظه طولانی کوتاه مدت نشان می دهد. همان طور که مشاهده می شود نمودار خطا دارای سیر نزولی و نمودار صحت دارای سیر صعودی است. در ایپاک های آخر نمودارهای داده های آموزشی و اعتبارسنجی همگرا می شوند. صحت روی داده های آموزشی از ۶۰ درصد شروع شده و به ۹۴.۴ درصد می رسد. و برای داده های اعتبارسنجی صحت از ۶۵ درصد شروع شده و به ۹۴.۵ درصد می رسد. همچنین تابع خطا نیز برای داده های آموزشی از ۱۰۴ شروع شده و به ۱۲ درصد کاهش پیدا می کند. برای داده های اعتبارسنجی نیز تابع خطا از ۱۰۱ درصد شروع شده و به ۱۲ درصد کاهش پیدا می کند.



شکل ۵-۳۳: نمودار خطا و صحت برای شبکه حافظه کوتاه مدت ماندگار پیچشی

پس از آموزش مدل را روی داده های تست آزمایش می کنیم. برای حالت میانگین ۵ مدل fold cross validation مدل دارای دقت ۰.۹۴ و صحت ۰.۹۳۹ و پوشش ۰.۹۴۱ درصد است. مقادیر گفته شده به صورت کامل در شکل ۵-۲۸ قابل مشاهده است. در مقایسه با شبکه عصبی کانولوشنی نوع اول می توان گفت در حالت میانگین نتایج شبیه به هم هستند اما در حالت کلی شبکه عصبی حافظه کوتاه مدت ماندگار پشته ای^{۱۹} عملکرد بهتری داشته است.

---Final Test Scores Averaged over Folds---

accuracy=0.944537253591714

precision=0.9450261084098219


recall=0.9462053494623178

f1=0.9444664453304888

per-class f1=[0.99181074 0.93907563 0.96336207 0.94250282 0.90926457 0.92078285]

شکل ۵-۳۴: نتایج آزمایش داده های تست بر روی شبکه عصبی حافظه کوتاه مدت ماندگار پشته ای

همچنین در شکل ۵-۲۹ می توان ماتریس درهم ریختگی را برای سه داده ی تست ، آموزش و اعتبارسنجی مشاهده کرد.




شکل ۵-۳۵: ماتریس درهم ریختگی شبکه حافظه کوتاه مدت ماندگار پشته ای

۷-۲-۵ شبکه عصبی حافظه طولانی کوتاه مدت دوطرفه در معماری نوع


دوم

در این آزمایش همین معماری شبکه عصبی حافظه طولانی کوتاه مدت نوع دوم را نگه داشته اما بجای استفاده از شبکه حافظه طولانی کوتاه مدت ساده از شبکه حافظه طولانی کوتاه مدت دو طرفه استفاده می کنیم. مراحل کامپایل و آموزش همانند مراحل قبل است.



شکل ۵-۳۶: معماری کلی شبکه حافظه کوتاه مدت دو طرفه ماندگار پشته ای

بعد از آموزش مدل نمودارهای خطا و صحت را بر حسب ایپاک رسم می کنیم. شکل ۵-۳۱ نمودارهای خطا و صحت بر حسب ایپاک در داده های آموزشی و اعتبارسنجی برای مدل شبکه های عصبی حافظه طولانی کوتاه مدت دو طرفه نوع دوم را نشان می دهد. همانطور که مشاهده می شود نمودار خطا دارای سیر نزولی و نمودار صحت دارای سیر صعودی است و در ایپاک های آخر نمودارهای داده های آموزشی و اعتبارسنجی همگرا می شوند. صحت روی داده های آموزشی از ۶۰ درصد شروع شده و به ۹۷ درصد می رسد و برای داده های اعتبارسنجی صحت از ۶۰ درصد شروع شده و به ۹۶ درصد می رسد. همچنین تابع خطا نیز برای داده های آموزشی از ۱۰۴ شروع شده و به ۷ درصد کاهش پیدا می کند. برای داده های اعتبارسنجی نیز تابع خطا از ۱۰۰ درصد شروع شده و به ۱۶ درصد کاهش پیدا می کند.



شکل ۵-۳۷: نمودار خطا و صحت برای شبکه حافظه کوتاه مدت ماندگار دوطرفه نوع دوم


پس از آموزش مدل را روی داده های تست آزمایش می کنیم و به صحت ۹۴.۴ درصد می رسیم. برای حالت میانگین، مدل دارای دقت ۹۵.۱ درصد، پوشش ۹۵.۱ درصد و نمره f1 ۹۵ درصد است. مقادیر

گفته شده به صورت کامل در شکل ۵-۳۳ قابل مشاهده است. در مقایسه با شبکه عصبی حافظه طولانی کوتاه مدت ساده می توان گفت که صحت مدل مشابه مدل قبلی است اما میزان دقت و پوشش آن بهبود پیدا کرده است. پوشش مدل از ۹۴ درصد به ۹۵ بهبود پیدا کرده است و نمره $f1$ نیز از ۹۴.۴ درصد به ۹۵ درصد بهبود پیدا کرده است.

```
---Final Test Scores Averaged over Folds---
accuracy=0.94954894754427
precision=0.9510100630672883
recall=0.9513074667142303
f1=0.9502985121151606
per-class f1=[0.99634369 0.95278069 0.97639485 0.96091954 0.89583333 0.91951896]
```

شکل ۵-۳۸: نتایج آزمایش داده های تست بر روی شبکه حافظه کوتاه مدت ماندگار دوطرفه نوع دوم

همچنین در تصویر زیر می توانید ماتریس درهم ریختگی مربوط به این مدل را مشاهده کنید.



شکل ۵-۳۹: ماتریس درهم ریختگی شبکه حافظه طولانی کوتاه مدت دوطرفه نوع دوم

۵-۲-۸ شبکه منتخب

با توجه به ارزیابی مدل هایی که در این فصل انجام شد ، مدل شبکه عصبی عمیق کانولوشنی حافظه طولانی کوتاه مدت به عنوان بهترین مدل نسبت به بقیه مدل ها معرفی می شود. این مدل دارای صحت ۹۵ درصد و همچنین نمره $f1$ ۹۵ درصد روی داده تست است که در مقایسه با مدل های دیگر بالاترین نتیجه را در پی داشته است.

همچنین با بررسی نمودارهای خطا و صحت می توان گفت این مدل در مقایسه در شبکه های عصبی حافظه طولانی کوتاه مدت و کانولوشنی آموزش بهتری نیز داشته است.

فصل ششم

نتیجه گیری و پیشنهادات

۶-۱ جمع بندی و نتیجه گیری

هدف نهایی این پروژه، پیاده سازی سیستم تشخیص فعالیت انسانی بر اساس داده های شتاب سنج وژیروسکوپ گوشی های هوشمند است.

برای رسیدن به این هدف، در فصل ابتدایی به ارائه مقدمه ای بر تشخیص فعالیت انسانی پرداختیم. سپس در فصل دو به بررسی مفاهیم پایه و روش ها و الگوریتم ها برای پیاده سازی این سیستم پرداختیم. در فصل سوم پیشینه موضوع و الگوریتم های قدیمی که تا به حال برای تشخیص و دسته بندی فعالیت های انسانی به کار رفته است را بررسی کردیم و در فصل چهارم به ارائه ابزارهای مورد نیاز جهت پیاده سازی و مجموعه داده مورد استفاده پرداختیم. در فصل پنجم به ریز جزئیات پیاده سازی، مراحل پیش پردازش و جاسازی داده، آموزش و ارزیابی شبکه های عصبی با پارامترهای مختلف پرداختیم و معیارهای ارزیابی را برای هر کدام محاسبه کردیم.

در این پژوهش به بررسی چهار نوع شبکه عصبی کانولوشنی، حافظه کوتاه مدت ماندگار، حافظه کوتاه مدت ماندگار دو طرفه و شبکه عمیق کانولوشنی حافظه کوتاه مدت ماندگار پرداختیم. در شبکه عصبی کانولوشنی سه نوع معماری را بررسی کردیم و در هر کدام به بررسی تاثیر استفاده از تابع فعال سازی رلو، تانژانت هذلولوی پرداختیم. از بین تمام شبکه های عصبی کانولوشنی بررسی شده، شبکه عصبی کانولوشنی نوع دوم با تابع فعالیت رلو بهترین عملکرد را دارد. این شبکه دارای یک لایه کانولوشن، یک لایه حذف تصادفی، یک لایه max-pooling و یک لایه flattent و یک لایه dense است.

در شبکه عصبی حافظه کوتاه مدت ماندگار به بررسی دو نوع معماری پرداختیم و همچنین استفاده از شبکه عصبی حافظه کوتاه مدت ماندگار دو طرفه را بررسی کردیم. شبکه ی عصبی حافظه کوتاه مدت ماندگار دو طرفه پشته ای دارای تقریباً میانگین صحت بالاتری بوده است. میانگین صحت برای این نوع شبکه ۹۵ درصد بوده است. با بررسی نتایج شبکه عصبی حافظه کوتاه مدت ماندگار دو طرفه و شبکه عصبی حافظه کوتاه مدت ماندگار متوجه شدیم که شبکه عصبی دو طرفه دارای دقت بالاتری نسبت به شبکه ی دوم است.

شبکه عصبی عمیق کانولوشنی حافظه کوتاه مدت ماندگار دارای دقت کمتری نسبت به شبکه عصبی حافظه کوتاه مدت ماندگار دو طرفه پشته ای است.

جدول ۶-۱: مقایسه بهترین شبکه‌ها از هر نوع

نوع شبکه عصبی	صحت	دقت	پوشش
شبکه عصبی کانولوشنی	93.31	93.32	93.45
شبکه عصبی حافظه کوتاه مدت ماندگار	94.45	94.50	94.62
شبکه عصبی کوتاه مدت ماندگار دو طرفه	94.95	95.10	95.13
شبکه عصبی عمیق کانولوشنی کوتاه مدت ماندگار	94.38	94.44	94.54

۲-۶ پیشنهادات

برای بهبود این پژوهش می‌توان رویکردهای مختلفی را در نظر گرفت که در این بخش به معرفی برخی از آنها می‌پردازیم. یکی از اقداماتی که می‌توان برای بهبود این پروژه انجام داد این است که تشخیص فعالیت‌های انسانی در سطح وسیع‌تری انجام شود. به این معنی که از روی داده‌هایی که داریم فقط ۶ نوع فعالیت را بررسی نکنیم و تعداد این فعالیت‌ها را افزایش دهیم.

همچنین می‌توانیم از شبکه‌های عصبی مختلف به صورت ترکیبی استفاده کرده و معماری جدیدی پیشنهاد دهیم تا صحت مدل‌ها افزایش یابد.

در بحث پیش‌پردازش ما در این پروژه فیلترهای مختلفی را اعمال کردیم تا نویزهایی که در داده‌ها وجود دارد را حذف کنیم. می‌توان مدلی طراحی کرد که نویز موجود در داده‌ها را کامل حذف کند و در واقع بتوان از داده‌های سنسورهای دیگر نیز استفاده کرد.

یکی از روش‌های جدیدی که در این حوزه استفاده می‌شود استفاده از شبکه‌های عصبی به شکل گراف^۱ است. با استفاده از این معماری می‌توان از روابط بین هر کدام از نودها هم استفاده کرد و مدلی با دقت خیلی بالاتر پیشنهاد داد. حتی با این معماری می‌توان روابط بین فعالیت‌های مختلف را نیز بدست آورد.

^۱ Graph Neural Network

کتاب نامه

- [1] What is in neural network? Accessed on July 5, 2023.
- [2] Activation functions introduction in neural network. Accessed on July 15, 2023.
- [3] How to use learning rate annealing with neural networks? Accessed on July 23, 2023.
- [4] Understanding lstm networks colah's blog. Accessed on July 23, 2023.
- [5] How lstm works? Accessed on July 2, 2023.
- [6] bi-lstm (long short term memory). Accessed on July 1, 2023.
- [7] "deep learning", [Online]. https://fa.wikipedia.org/w/index.php?title=%DB%8C%D8%A7%D8%AF%DA%AF%DB%8C%D8%B1%DB%8C_%D8%B9%D9%85%DB%8C%D9%82&oldid=34699203, 2023.
- [8] What is neural network [Online]. https://fa.wikipedia.org/w/index.php?title=%D8%B4%D8%A8%DA%A9%D9%87_%D8%B9%D8%B5%D8%A8%DB%8C_%D9%85%D8%B5%D9%86%D9%88%D8%B9%DB%8C&oldid=35452563, July 2023.
- [9] "activation function in neural networks", [Online]. <https://blog.faradars.org/%D8%AA%D8%A7%D8%A8%D8%B9-%D9%81%D8%B9%D8%A7%D9%84%D8%B3%D8%A7%D8%B2%DB%8C-%D8%AF%D8%B1-%D8%B4%D8%A8%DA%A9%D9%87-%D9%87%D8%A7%DB%8C-%D8%B9%D8%B5%D8%A8%DB%8C/>, August 2023.

- [10] Adam algorithm, simple explanation. <https://blog.faradars.org/%D8%A7%D9%84%DA%AF%D9%88%D8%B1%DB%8C%D8%AA%D9%85-%D8%A8%D9%87%DB%8C%D9%86%D9%87-%D8%B3%D8%A7%D8%B2%DB%8C-%D8%A2%D8%AF%D8%A7%D9%85/>, July 2023.
- [11] "regularization in machine learning", [Online]. <https://blog.tarjomyar.ir/%D8%B1%DA%AF%D9%88%D9%84%D8%A7%D8%B1%DB%8C%D8%B2%D8%A7%D8%B3%DB%8C%D9%88%D9%86-%D8%AF%D8%B1-%DB%8C%D8%A7%D8%AF%DA%AF%DB%8C%D8%B1%DB%8C-%D9%85%D8%A7%D8%B4%DB%8C%D9%86-nqtmtdbzkvfia>, August 2023.
- [12] "l1 regularization", [Online]. <https://www.mlglossary.ir/1/l1-regularization/>, August 2023.
- [13] "gradient descent", [Online]. https://fa.wikipedia.org/w/index.php?title=%D8%A7%D8%AF%DB%8C%D8%A7%D9%86_%D8%A9%D8%A7%D9%87%D8%B4%DB%8C&oldid=35244978, 2023.
- [14] "what are neural networks?", [Online]. <https://www.ibm.com/topics/neural-networks>, 2023.
- [15] "backpropagation", [Online]. <https://en.wikipedia.org/w/index.php?title=Backpropagation&oldid=1133837385>, July 2023.
- [16] "vanishing and exploding gradients in deep neural networks", [Online]. <https://www.analyticsvidhya.com/blog/2021/06/the-challenge-of-vanishing-exploding-gradients-in-deep-neural-networks/>, July 2023.
- [17] Ying, Xue. An overview of overfitting and its solutions. Journal of Physics: Conference Series, 1168(2):022022, feb 2019.

- [18] Hamed Habibi Aghdam, Elnaz Jahani Heravi. Guide to convolutional neural networks : a practical application to traffic-sign detection and classification. 2023.
- [19] Time series classification [Online]. <https://machinelearningmastery.com/cnn-models-for-human-activity-recognition-time-series-classification/>, July 2023.
- [20] "convolutional neural networks", [Online]. <https://web.archive.org/web/20171228091645/http://deeplearning.net/tutorial/lenet.html>, July 2023.
- [21] Ciregan, Dan, Meier, Ueli, and Schmidhuber, Jϯrgen. Multi-column deep neural networks for image classification. in 2012 IEEE Conference on Computer Vision and Pattern Recognition, pp. 3642–3649, 2012.
- [22] "recurrent neural network", [Online]. https://en.wikipedia.org/wiki/Recurrent_neural_network, July 2023.
- [23] "what are recurrent neural networks?", [Online]. <https://www.ibm.com/topics/recurrent-neural-networks>, July 2023.
- [24] "lstm network" [Online]. <https://cafetadris.com/blog/%D8%B4%D8%A8%DA%A9%D9%87%E2%80%8C%D8%B9%D8%B5%D8%A8%DB%8C-lstm/>, July 2023.
- [25] "1d convolutional neural network models for human activity recognition" [Online]. <https://machinelearningmastery.com/cnn-models-for-human-activity-recognition-time-series-classification/>, July 2023.
- [26] "bi-lstm", [Online]. <https://medium.com/@raghavaggarwal0089/bi-lstm-bc3d68da8bd0>, July 2023.

- [27] Different ways to combine cnn and lstm networks for time series classification task. <https://medium.com/@mixanyy/different-ways-to-combine-cnn-and-lstm-networks-for-time-series-classification-t> July 2023.
- [28] Guide on Support Vector Machine(SVM),[Online]. <https://www.analyticsvidhya.com/blog/2021/10/support-vector-machinessvm-a-complete-guide-for-beginners/#:~:text=SVM%20is%20a%20powerful%20supervised,work%20best%20in%20classification%20problems.>, August 2023.
- [29] Tran, Duc Ngoc and Phan, Duy Dinh. Human activities recognition in android smartphone using support vector machine. in 2016 7th International Conference on Intelligent Systems, Modelling and Simulation (ISMS), pp. 64–68, 2016.
- [30] Kwapisz, Jennifer R., Weiss, Gary M., and Moore, Samuel. Activity recognition using cell phone accelerometers. SIGKDD Explor., 12:74–82, 2011.
- [31] ”transfer learning”,[Online]. https://fa.wikipedia.org/wiki/%DB%8C%D8%A7%D8%AF%DA%AF%DB%8C%D8%B1%DB%8C_%D8%A7%D9%86%D8%AA%D9%82%D8%A7%D9%84, July 2023.
- [32] Tang, Tao, Zheng, Lingxiang, Weng, Shaolin, Peng, Ao, and Zheng, Huiru. Human activity recognition with smart watch based on h-svm. pp. 179–186, 01 2018.
- [33] ”random-forest” [Online]. https://fa.wikipedia.org/wiki/%D8%AC%D9%86%DA%AF%D9%84_%D8%AA%D8%B5%D8%A7%D8%AF%D9%81%DB%8C, August 2023.
- [34] Kumar, Prabhat and Suresh, S. Flaap: An open human activity recognition (har) dataset for learning and finding the associated activity patterns. Procedia Com-

- puter Science, 212:64–73, 2022. 11th International Young Scientist Conference on Computational Science.
- [35] "what is tensorflow? how it works? introduction and architecture" [Online]. <https://www.guru99.com/what-is-tensorflow.html>, June 2023.
- [36] "what is numpy" [Online]. <https://numpy.org/doc/stable/user/whatisnumpy.html>, June 2023.
- [37] "keras ", [Wikipedia]. <https://en.wikipedia.org/w/index.php?title=Keras&oldid=1109254674>, June 2023.
- [38] Learn pandas in python ,[Online]. <https://blog.faradars.org/pandas-from-zero-to-hero/>, January 2023.
- [39] "what is matplotlib in python? how to use it for plotting? - activestate", [Online]. <https://www.activestate.com/resources/quick-reads/what-is-matplotlib-in-python-how-to-use-it-for-plotting>, January 2023.
- [40] "scikit-learn", [Online]. <https://radimrehurek.com/gensim/intro.html>, 2023.
- [41] "median filter", [Online]. https://fa.wikipedia.org/wiki/%D9%81%DB%8C%D9%84%D8%AA%D8%B1_%D9%85%DB%8C%D8%A7%D9%86%D9%87, 2023.
- [42] "butterworth filter", [Online]. <https://www.collimator.ai/reference-guides/what-is-a-butterworth-filter>, 2023.